

ANÁLISE SEMÂNTICA APLICADA À DESCRIÇÃO DE DOCUMENTOS DE ARQUIVO

Como técnicas de Processamento de Linguagem Natural podem apoiar a auditoria de Tabelas de Temporalidade

Vinícius Augusto de Souza
va.vinicius@gmail.com

jul 20, 2026

DOI <https://doi.org/10.5281/zenodo.21994964>

1. INTRODUÇÃO

A gestão de documentos depende de um conjunto de instrumentos técnicos destinados a garantir que cada documento permaneça sob guarda pelo tempo necessário e receba a destinação final adequada. Entre esses instrumentos, a Tabela de Temporalidade ocupa posição central, pois estabelece os prazos de guarda e define quais documentos serão eliminados e quais serão preservados permanentemente.

Na prática, porém, a confiabilidade desse instrumento não depende apenas da qualidade da tabela em sua elaboração inicial. Ela depende, sobretudo, da consistência com que os documentos são classificados ao longo dos anos.

Com o crescimento contínuo da produção documental, mudanças nas rotinas administrativas e a atuação de diferentes servidores na classificação dos documentos, é comum que um mesmo código passe a reunir documentos com conteúdos cada vez mais heterogêneos. Em outros casos, documentos são classificados incorretamente, permanecendo ocultos em séries documentais que não correspondem ao seu contexto de produção.

Essas situações produzem um processo gradual de degradação, digamos assim, da classificação documental. O problema nem sempre é perceptível durante as atividades rotineiras do Arquivo, mas pode comprometer diretamente a avaliação documental, a recuperação da informação e até mesmo a segurança jurídica da instituição. Um código excessivamente abrangente pode levar, por exemplo, à eliminação prematura de documentos relevantes ou, no extremo oposto, manter sob guarda permanente documentos cujo valor já se extinguiu.

Tradicionalmente, a identificação dessas inconsistências depende de inspeções manuais, leitura por amostragem ou pesquisas baseadas em palavras-chave. Embora essas estratégias continuem sendo importantes, elas apresentam limitações quando aplicadas a grandes massas documentais. Pequenas diferenças de vocabulário podem ocultar documentos semanticamente equivalentes, enquanto descrições semelhantes podem representar atividades administrativas completamente distintas.

Considere, por exemplo, duas descrições documentais:

- Encaminhamento de estagiário;
- Alocação de bolsista.

Sob a perspectiva de uma busca textual tradicional, trata-se de expressões diferentes. Entretanto, dependendo do contexto administrativo, ambas podem representar documentos pertencentes à mesma função e, portanto, sujeitos ao mesmo prazo de guarda. O problema inverso também ocorre: descrições semelhantes podem corresponder a séries documentais distintas. Esse cenário abre espaço, portanto, para o emprego de técnicas de Processamento de Linguagem Natural (PLN). Em vez de procurar palavras específicas, essas técnicas permitem analisar a proximidade semântica entre descrições documentais, identificando padrões dificilmente perceptíveis por simples inspeção visual.

O objetivo deste artigo é apresentar uma metodologia de auditoria baseada em análise semântica capaz de auxiliar o arquivista na identificação de possíveis inconsistências classificatórias, códigos excessivamente abrangentes e oportunidades de revisão da Tabela de Temporalidade. A proposta, é claro, não substitui a avaliação arquivística, nem automatiza decisões de classificação. Seu propósito é fornecer indicadores objetivos que auxiliem o profissional a concentrar seus esforços exatamente nos pontos onde há maior probabilidade de ocorrência de problemas.

Nos tópicos seguintes serão apresentados os fundamentos da metodologia, a interpretação das métricas utilizadas e dois estudos de caso obtidos durante uma auditoria realizada sobre uma base documental real.

2. O QUE SIGNIFICA ANALISAR A SEMÂNTICA DE UMA TABELA DE TEMPORALIDADE?

Quando um arquivista classifica um documento, sua decisão não é baseada apenas nas palavras presentes na descrição documental. A classificação considera principalmente o contexto de produção, a função administrativa desempenhada e a atividade que deu origem ao documento. Entretanto, na prática cotidiana, os sistemas informatizados normalmente armazenam apenas uma breve descrição textual do documento. Essa descrição passa a representar, ainda que de forma imperfeita, a atividade administrativa realizada, e é justamente sobre esse conjunto de descrições que a análise semântica atua.

Em vez de procurar palavras específicas, a metodologia proposta procura identificar o grau de proximidade entre os significados das descrições pertencentes a documentos reunidos sob um mesmo código de classificação. Quanto maior essa proximidade, maior a evidência de que aquele código continua reunindo documentos semanticamente coerentes. Por outro lado, quando surgem grupos de descrições claramente distintos, existe um indício de que o código em questão pode estar reunindo documentos de naturezas diferentes ou que parte dos documentos foi classificada incorretamente.

É importante destacar que a análise semântica não avalia o documento em si, nem substitui a interpretação arquivística do seu contexto de produção. O método analisa exclusivamente as descrições registradas na base de dados. Consequentemente, seus resultados dependem diretamente da qualidade dessas descrições.

Sob essa perspectiva, a análise semântica pode ser compreendida como um mecanismo de auditoria. Em vez de revisar milhares de registros individualmente, o profissional passa a concentrar seus esforços nos códigos que apresentam maior probabilidade de inconsistências, tornando o processo de revisão mais objetivo e escalável.

De forma resumida, a análise semântica responde a uma pergunta importante: *“Existem evidências de que este código reúne documentos com comportamentos semânticos diferentes?”*

Quando a resposta é positiva, inicia-se a etapa propriamente arquivística: verificar se essa diferença decorre de uma evolução natural da atividade administrativa, da necessidade de revisão da Tabela de Temporalidade ou simplesmente de erros de classificação.

3. A METODOLOGIA PROPOSTA

O método desenvolvido neste trabalho parte de uma ideia simples: cada código da Tabela de Temporalidade deve apresentar um comportamento semântico relativamente homogêneo.

Naturalmente, descrições documentais nunca são idênticas, pois pequenas variações de redação fazem parte da atividade administrativa. Espera-se encontrar expressões equivalentes, abreviações, mudanças de terminologia e diferentes formas de registrar uma mesma atividade. O problema surge quando essas diferenças deixam de ser apenas linguísticas e passam a representar funções administrativas distintas.

Para identificar esse comportamento, cada código de classificação é analisado individualmente. Todos os documentos pertencentes ao mesmo código são processados em conjunto, permitindo avaliar exclusivamente sua coerência interna. Dessa forma, evita-se comparar documentos que naturalmente pertencem a séries documentais diferentes.

A metodologia é composta por quatro etapas sucessivas:

1. Representação das descrições documentais

Inicialmente, cada descrição textual é convertida em uma representação numérica capaz de preservar as diferenças de vocabulário existentes entre os documentos. Essa transformação permite que descrições semelhantes ocupem posições próximas em um espaço matemático, enquanto descrições semanticamente distintas tendem a afastar-se umas das outras.

2. Redução da dimensionalidade

Como descrições administrativas costumam utilizar um vocabulário relativamente amplo, essa representação inicial possui centenas ou milhares de dimensões. Para facilitar a identificação de padrões, aplica-se uma técnica de redução de dimensionalidade, preservando as estruturas semânticas mais relevantes e reduzindo a influência de variações pouco significativas.

3. Identificação de agrupamentos

Com as descrições já representadas em um espaço de menor dimensionalidade, aplica-se um algoritmo de agrupamento cujo objetivo é verificar se o código analisado apresenta um único comportamento semântico predominante ou se existem subconjuntos claramente distintos de documentos.

É importante observar que esses agrupamentos não representam novas séries documentais. Eles representam apenas comportamentos linguísticos semelhantes encontrados dentro do mesmo código de classificação.

4. Avaliação da consistência

Finalmente, calcula-se uma métrica capaz de medir simultaneamente a coesão interna de cada agrupamento e a distância entre os diferentes agrupamentos identificados. Essa medida fornece um indicador quantitativo da homogeneidade semântica do código analisado e serve como base para a interpretação arquivística dos resultados.

4. COMO INTERPRETAR OS RESULTADOS DA AUDITORIA

Ao concluir o processamento de um código de classificação, o método produz um indicador numérico que expressa o grau de homogeneidade semântica das descrições documentais analisadas.

A interpretação desse indicador deve ser feita sempre sob a perspectiva arquivística. Seu objetivo não é determinar automaticamente se um código está correto ou incorreto, mas indicar quais códigos merecem uma análise mais detalhada.

De forma geral, três situações podem ocorrer:

1. Códigos semanticamente homogêneos

Quando as descrições documentais apresentam elevado grau de semelhança entre si, os documentos tendem a formar um único agrupamento semântico. Nesse cenário, pequenas diferenças de redação representam apenas variações naturais da linguagem administrativa, sem indicar necessariamente problemas de classificação.

Para o arquivista, portanto, esse comportamento indica que o código continua desempenhando adequadamente sua função de reunir documentos produzidos por uma mesma atividade administrativa.

2. Códigos com múltiplos agrupamentos

Em algumas situações, o método poderá identificar dois conjuntos de descrições claramente distintos dentro do mesmo código de classificação. Esse resultado não significa, por si só, que a classificação esteja incorreta. Existem diversas explicações possíveis, como, por exemplo:

- mudanças históricas na nomenclatura utilizada pelo órgão;
- evolução das atividades administrativas;
- utilização de descrições diferentes para documentos equivalentes;
- coexistência de documentos pertencentes a funções administrativas distintas.

Nesses casos, cabe ao arquivista analisar o contexto de produção dos documentos para verificar se a diferença observada representa apenas uma mudança terminológica ou se evidencia a necessidade de revisão da Tabela de Temporalidade.

3. Documentos semanticamente isolados

Também é possível que apenas um número reduzido de documentos apresente comportamento muito diferente do restante da série. Quando isso ocorre, a hipótese mais provável é a existência de inconsistências classificatórias decorrentes de erros de classificação, preenchimento inadequado das descrições ou utilização indevida do código.

Nessas situações, o método permite localizar rapidamente os registros divergentes, reduzindo significativamente o esforço necessário para sua conferência. Em todos os casos, o resultado da análise deve ser entendido como um mecanismo de priorização da auditoria, e não como uma decisão automática sobre a classificação documental.

5. O PAPEL DO *SCORE* DE SILHUETA

Uma vez identificados os agrupamentos semânticos, torna-se necessário avaliar se eles representam uma separação consistente ou apenas uma variação natural da linguagem utilizada nas descrições documentais. Para essa finalidade, foi empregada a métrica conhecida como Score de Silhueta (Silhouette Score), proposta por Peter J. Rousseeuw em 1987.

Essa métrica compara dois aspectos simultaneamente:

- **Coesão**, isto é, o grau de proximidade entre um documento e os demais documentos pertencentes ao mesmo agrupamento;

- **Separação**, correspondente à distância entre esse documento e o agrupamento semanticamente mais próximo.

Em termos intuitivos, espera-se que documentos pertencentes à mesma atividade administrativa permaneçam relativamente próximos entre si. Da mesma forma, espera-se que documentos de naturezas diferentes ocupem regiões distintas do espaço semântico. Quanto melhor essa separação, maior será o valor do índice obtido, que pode variar de -1 a 1.

É importante compreender que o “vizinho” considerado pelo algoritmo não corresponde ao código seguinte da Tabela de Temporalidade, nem ao documento armazenado na caixa ao lado. O vizinho é simplesmente o agrupamento semântico mais próximo encontrado dentro daquele mesmo código de classificação.

Essa interpretação possui uma consequência importante: quando o índice assume valores elevados (próximos de 1), o método está indicando que existem subconjuntos documentais suficientemente distintos para justificar uma posterior investigação arquivística. Por outro lado, índices reduzidos (próximos de 0) sugerem que as diferenças observadas decorrem apenas da variabilidade normal da linguagem administrativa.

Em outras palavras, o Score de Silhueta não mede a qualidade da Tabela de Temporalidade. Ele mede apenas o grau de separação semântica existente entre os documentos classificados sob um mesmo código. Essa distinção é fundamental para evitar interpretações equivocadas.

6. ANALISANDO ALGUNS CASOS PARADIGMÁTICOS

Para entender o poder dessa abordagem, apresentarei aqui dois casos reais e emblemáticos encontrados em uma auditoria particular que eu mesmo realizei, que são os resultados encontrados para o código de temporalidade 2.0.04.02.01, que corresponde à série documental “Boletim de Recebimento de Material”, e o código 1.0.06.03.02, que corresponde à série “Folders”.

A metodologia proposta foi aplicada sobre uma base documental real, composta por descrições documentais previamente classificadas segundo a Tabela de Temporalidade adotada pela instituição. O objetivo da auditoria não era avaliar toda a tabela simultaneamente, mas analisar individualmente cada código de classificação, verificando se suas descrições documentais permaneciam semanticamente coerentes ao longo do tempo.

6.1. Caso 1: Indícios de Necessidade de Ramificação

Rodamos o algoritmo para calcular a métrica do Score de Silhueta para o código 2.0.04.02.01. Sob a perspectiva arquivística, espera-se que uma série dessa natureza apresente elevado grau de homogeneidade, pois trata-se de um procedimento administrativo relativamente padronizado, normalmente produzido por unidades responsáveis pelo recebimento e conferência de materiais.

Por essa razão, a expectativa inicial era encontrar descrições documentais distribuídas de maneira uniforme, refletindo pequenas variações de linguagem, mas preservando uma única identidade semântica. No entanto, o índice calculado foi igual a 0.848. Um valor dessa magnitude constitui, portanto, um forte indício de que esse código em particular agrega mais de um comportamento semântico, justificando, desse modo, uma investigação mais detalhada.

É claro que o valor numérico, por si só, não explica o que está acontecendo. Para compreender o resultado, é necessário visualizar a distribuição dos documentos.




Figura 1 – Distribuição semântica dos documentos classificados no código 2.0.04.02.01.

Cada ponto representa um documento. A distância entre os pontos não corresponde à posição física dos documentos nem à sua ordem na base de dados, mas à proximidade semântica entre suas descrições. Quanto mais próximos dois pontos estão, maior a semelhança entre os textos que os originaram.

Nesse caso, do lado esquerdo do gráfico, formou-se um paredão denso em tons de azul escuro. São centenas de pontos perfeitamente alinhados e sobrepostos, que representa a massa de documentos corretos, confirmando que a base desse código de temporalidade está íntegra. Já no extremo oposto do gráfico, completamente isolado da nuvem principal através de um enorme vazio espacial, há um único ponto.

Visualmente, a conclusão instintiva era de que estávamos diante de um erro pontual de arquivamento. No entanto, analisando os resultados e a base de dados detalhadamente, verificamos que se tratam, na verdade, de vários pontos sobrepostos. Ademais, ao examinar o conteúdo das descrições pertencentes ao agrupamento minoritário, verificou-se que elas compartilhavam

características comuns entre si, formando um subconjunto documental consistente. Não se tratava de registros aleatórios dispersos pela base, mas de documentos com identidade própria.

A métrica do Score de Silhueta juntamente com uma investigação arquivística humana sugeriram, portanto, que o código de classificação em questão pode estar reunindo documentos cuja proximidade administrativa deixou de existir ao longo da evolução das atividades da instituição. Em outras palavras, a estrutura originalmente prevista pela Tabela de Temporalidade pode já não refletir adequadamente a realidade documental observada.

A análise semântica não determina que um novo código deva ser criado. Ela apenas evidencia que aquele documento ocupa uma posição semanticamente incompatível com o restante da série, fornecendo ao arquivista um indicativo objetivo de que a estrutura classificatória merece ser reavaliada.

Neste estudo, essa evidência foi suficiente para recomendar a análise de uma possível ramificação da Tabela de Temporalidade.

6.2. Caso 2: Quando um aparente agrupamento revela um erro de classificação

O segundo estudo de caso refere-se ao código 1.0.06.03.02 – Folders, cujo Score de Silhueta calculado foi de 0,407. Embora significativamente inferior ao caso anterior, esse valor ainda indica a existência de diferenças semânticas relevantes dentro do código analisado.

Entretanto, a interpretação correta não surge da leitura isolada da métrica. Ela surge da combinação entre a métrica e o gráfico.




Figura 2 – Distribuição semântica dos documentos classificados no código 1.0.06.03.02.

Observe inicialmente que a maior parte dos documentos concentra-se na região esquerda da figura. Esse comportamento é esperado, pois indica que a maior parte das descrições compartilha um vocabulário semelhante, formando assim um conjunto documental relativamente homogêneo.

Os documentos localizados na parte superior direita encontram-se distantes do agrupamento principal, mas permanecem relativamente isolados entre si, de tal modo que podemos inferir que eles não formam um novo conjunto documental. O elemento realmente importante do gráfico encontra-se na região inferior. Ali observa-se um pequeno agrupamento composto por três documentos, destacados em cor diferente pelo algoritmo. Embora esse conjunto não seja o mais distante do agrupamento principal, seus documentos apresentam uma característica fundamental: são semanticamente semelhantes entre si.

A metodologia proposta não procura simplesmente identificar os documentos mais afastados do conjunto principal. Seu objetivo é localizar agrupamentos semanticamente consistentes, ainda que compostos por poucos registros. Em outras palavras, a distância, por si só, não é suficiente para caracterizar uma inconsistência relevante. Para que um conjunto documental mereça atenção, é necessário que exista também coerência interna entre seus próprios documentos. Esse comportamento explica por que alguns registros visualmente mais afastados não foram destacados pelo algoritmo, enquanto os três documentos localizados na região inferior foram tratados como um agrupamento distinto.

Do ponto de vista arquivístico, essa distinção é extremamente útil. Um documento isolado pode representar apenas uma descrição incompleta, uma variação terminológica ou uma situação administrativa excepcional. Já um pequeno grupo de documentos que compartilha o mesmo comportamento semântico sugere a existência de um padrão, e padrões justificam uma investigação.

Para transformar essa evidência estatística em um procedimento de auditoria, adotou-se um critério operacional específico. Nesta implementação:

1. Agrupamentos divergentes contendo até três documentos são tratados como candidatos prioritários à revisão individual. A hipótese inicial é a ocorrência de inconsistências classificatórias.
2. Agrupamentos compostos por quatro ou mais documentos, por sua vez, passam a indicar uma situação diferente. Nesse caso, considera-se plausível que o código esteja reunindo uma atividade administrativa distinta, recomendando-se avaliar a necessidade de revisão da Tabela de Temporalidade.

É importante destacar que esse limite não constitui uma regra arquivística nem uma propriedade matemática do algoritmo. Trata-se de um parâmetro operacional adotado para esta auditoria, que poderá ser ajustado conforme o volume documental, as características da instituição e a experiência acumulada durante futuras aplicações.

No caso analisado, a conferência manual das descrições confirmou a hipótese inicial. Os três documentos destacados correspondiam efetivamente a registros classificados em código incompatível com sua natureza documental. Esse resultado evidencia uma das principais

contribuições práticas da metodologia: em vez de exigir a leitura integral de toda a série documental, a auditoria direcionou imediatamente a atenção do arquivista para um pequeno conjunto de registros com elevada probabilidade de inconsistência, reduzindo significativamente o esforço necessário para a revisão.

Entretanto, à medida que se percorre o gráfico em direção à direita, começam a surgir documentos cada vez mais afastados do agrupamento principal. O aspecto mais interessante não é a existência desses documentos dispersos, mas o fato de que eles não formam um novo agrupamento consistente:

- Alguns aparecem isolados na parte superior da figura;
- Outros ocupam posições intermediárias.

Esse padrão é completamente diferente daquele observado no estudo de caso anterior. Enquanto o primeiro exemplo apresentava uma separação clara entre dois comportamentos semânticos, aqui observamos uma dispersão gradual das descrições sem que surja um segundo grupo documental suficientemente coeso. Essa diferença é decisiva para a interpretação arquivística.

Como interpretar um gráfico de análise semântica

Ao analisar a distribuição dos documentos, não observe apenas quais pontos estão mais distantes do agrupamento principal. Observe também quais pontos permanecem próximos entre si.

A auditoria proposta não busca apenas documentos isolados. Ela procura identificar pequenos grupos semanticamente coerentes, pois são esses agrupamentos que oferecem os indícios mais consistentes para investigação arquivística.

7. CONCLUSÃO

Com a introdução de algoritmos de Processamento de Linguagem Natural e métricas matemáticas como o Score de Silhueta nós deixamos de procurar palavras-chave isoladas em planilhas intermináveis e passamos a aplicar a geometria de alta dimensão para auditar o sentido, a semântica e a coesão das nossas tabelas de temporalidade.

Como vimos nos casos práticos, a máquina consegue diferenciar com precisão o que é uma anomalia estrutural — exigindo a criação de uma nova ramificação na tabela — e o que é uma falha pontual de operação, apontando o momento exato em que um documento vital foi classificado erroneamente.

O verdadeiro valor dessa abordagem, no entanto, não está apenas na elegância do código Python, mas no impacto direto na conformidade legal e na otimização de espaço. Uma tabela de

temporalidade corrompida é um risco gigantesco: ela pode levar à eliminação precoce de documentos que deveriam ser guardados por décadas, ou forçar a instalação a gastar recursos preciosos armazenando lixo administrativo para sempre.