

SOBREPOSIÇÃO SEMÂNTICA APLICADA À DESCRIÇÃO DE DOCUMENTOS DE ARQUIVO

Vinícius Augusto de Souza
va.vinicius@gmail.com

jul 21, 2026

DOI <https://doi.org/10.5281/zenodo.21995516>

1. DIVERGÊNCIA INTERNA VS. CONVERGÊNCIA EXTERNA

Embora a preparação dos dados compartilhe a mesma base matemática que mostramos em nosso artigo anterior — a transformação das descrições textuais em vetores numéricos (TF-IDF) e a compactação desse vocabulário em um espaço geométrico otimizado (SVD) —, as ferramentas analíticas que serão aplicadas a seguir tomam caminhos matemáticos diferentes, de acordo com o objetivo da auditoria.

Para estruturar a Tabela de Temporalidade de forma eficiente, a Inteligência Artificial precisou responder a duas perguntas distintas: (1) Onde precisamos criar novas divisões? e (2) Onde precisamos fundir categorias repetidas? Para cada pergunta, utilizamos um motor algorítmico específico:

a) A Busca por Ramificações (Divergência Interna)

Quando o objetivo é identificar se um código abrangente precisa ser ramificado, o algoritmo olha exclusivamente para dentro de uma única categoria. Neste cenário, utilizamos a Clusterização via K-Means combinada com o Score de Silhueta. A máquina tenta fatiar a nuvem de documentos de um mesmo código em dois subgrupos e mede a coesão dessa separação. O objetivo matemático aqui é encontrar divergência interna: provar que um único “guarda-chuva” administrativo está escondendo rotinas de naturezas tão diferentes que justifiquem a criação de subcategorias para um arquivamento mais preciso.

b) A Busca por Redundâncias (Convergência Externa)

Já no caso das redundâncias, a lógica se inverte. O algoritmo não tenta dividir nada; em vez disso, ele olha de fora, comparando categorias administrativas diferentes. Aqui, a ferramenta matemática escolhida foi a Distância Euclidiana entre Centroides. O sistema calcula o “centro de gravidade” da nuvem de documentos de um dado Código A e afere a distância geométrica exata até o centro de gravidade de um dado Código B. O objetivo é detectar a convergência externa: provar que dois códigos de temporalidade que deveriam representar realidades documentais distintas estão, na prática, ocupando o mesmíssimo espaço semântico na base global.

Em suma: enquanto a técnica de Ramificações utiliza o K-Means para apontar categorias que precisam ser divididas, a técnica de Redundâncias utiliza a medição Euclidiana para apontar categorias que precisam ser fundidas. É a combinação desses dois vetores opostos que garante o enxugamento e a precisão do acervo logístico.

2. SEPARANDO REDUNDÂNCIA REAL DA “ILUSÃO BUROCRÁTICA”

Quando aplicamos a geometria de alta dimensão (SVD) para encontrar códigos redundantes e enxugar a Tabela de Temporalidade, esbarramos em um dos maiores desafios do Processamento de Linguagem Natural (PLN): a poluição semântica trazida pelo uso dos jargões corporativos.

Em um cenário ideal, documentos sobre o mesmo assunto habitam o mesmo espaço vetorial, provando que a distinção administrativa entre eles é inútil e que seus códigos podem ser unificados. Contudo, na gestão documental real, descobrimos que a máquina pode ser facilmente enganada pelo “burocratês”. De fato, vejamos alguns resultados experimentais que encontrei em minha base de dados.

Durante a varredura do acervo, ao cruzar milhares de combinações possíveis com um rigoroso limiar de distância semântica, o algoritmo isolou 9 pares de códigos estruturalmente muito próximos (com distâncias minúsculas, na casa de 0.02). Do ponto de vista da matemática, tais pares de códigos eram semanticamente idênticos. Porém, ao submetemos esses agrupamentos a uma inspeção qualitativa, extraíndo o peso real do vocabulário via TF-IDF, o resultado revelou que alguns pares eram, na verdade, falsos positivos.

2.1. Os Falsos Positivos

A inteligência artificial identificou proximidade extrema em vários pares que, sob o olhar arquivístico, não poderiam ser fundidos. Geometricamente, eles habitavam a mesma nuvem porque compartilham verbos e conectivos administrativos comuns, criando uma forte ilusão de identidade vocabular. Vejamos três exemplos reais extraídos da base onde a máquina se confundiu.

Primeiramente, os resultados encontrados foram os seguintes:

Par	Codigo_Principal	Codigo_Redundante_Sugerido	Distancia_Semantica	Status
1	5.3.04.00.14	5.3.04.00.15	0,0212	Eliminar e Absorver (Distinção Administrativa Redundante)
2	2.0.04.02.02	5.3.05.00.11	0,0217	Eliminar e Absorver (Distinção Administrativa Redundante)
3	5.3.01.00.11	5.3.02.01.15	0,0229	Eliminar e Absorver (Distinção Administrativa Redundante)
4	5.3.02.01.51	5.3.02.01.57	0,0235	Eliminar e Absorver (Distinção Administrativa Redundante)
5	5.3.02.01.51	5.3.02.01.64	0,0238	Eliminar e Absorver (Distinção Administrativa Redundante)
6	5.3.02.01.42	5.3.02.01.52	0,0244	Eliminar e Absorver (Distinção Administrativa Redundante)
7	2.0.01.00.01	5.3.02.01.02	0,025	Eliminar e Absorver (Distinção Administrativa Redundante)
8	5.3.02.01.48	5.3.02.01.58	0,0297	Eliminar e Absorver (Distinção Administrativa Redundante)
9	5.3.02.01.31	5.3.02.01.45	0,0298	Eliminar e Absorver (Distinção Administrativa Redundante)

Par 7:

O modelo aproximou o Código 2.0.01.00.01 (Prontuários de Servidores) do 5.3.02.01.02 (Atestados/ Declarações de Vagas, Escolaridade e Frequência). Porém, a inspeção de palavras-chave revelou que o primeiro trata de ['certidao', 'prontuario', '1996', 'ferias'], enquanto o segundo foca em ['atestado', 'medica', 'licenca', 'guia']. São rotinas de RH com ciclos de vida legais totalmente diferentes que colidiram possivelmente por jargões comuns.




Figura 1 – Falso Positivo. O gráfico mostra a sobreposição perfeita sugerida pelo algoritmo, mas a inspeção dos termos-chave provou tratar-se de assuntos distintos unidos por jargão genérico de RH.

Par 3:

O Código 5.3.01.00.11 ['dados', 'processamento', 'prodesp'] foi matematicamente sobreposto ao 5.3.02.01.15 ['relatorio', 'aluno', 'acompanhamento']. O primeiro lida com TI e sistemas do estado (Orientações para utilização do sistema Processamento de Dados do Estado de São Paulo), o segundo com o desempenho estudantil (Relatório de acompanhamento do Aluno do Ensino Fundamental).

Par 9:

O algoritmo sugeriu fundir o Código 5.3.02.01.31 ['pais', 'reuniao', 'ata', 'presenca'] com o 5.3.02.01.45 ['professor', 'plano', 'projeto', 'planejamento']. Embora ambos sejam do ecossistema

escolar, atas de reunião de pais e planos de ensino de professores possuem naturezas documentais e tempos de guarda distintos.

Em todos esses casos, fundir os códigos seria um erro grave. A matemática falhou porque os redatores usam estruturas textuais quase idênticas para relatar rotinas diferentes.

2.2. A Redundância Genuína

Por outro lado, o teste de estresse validou o poder da ferramenta ao expor o inchaço histórico da tabela de temporalidade em uma área específica. O script apontou um choque frontal e múltiplo entre os Códigos 5.3.02.01.51, 5.3.02.01.57, 5.3.02.01.64, 5.3.02.01.48 e 5.3.02.01.58 (refletidos nos Pares 4, 5 e 8 do relatório).

Ao inspecionarmos o peso semântico, a sobreposição foi irrefutável. Todos esses códigos giravam rigorosamente em torno do mesmo núcleo duro de palavras: ['vagas', 'potenciais', 'reais', 'listagem', 'substituicao', 'mudanca', 'remocao'].




Figura 2 – Redundância Genuína. Aqui a sobreposição geométrica reflete a realidade documental: múltiplos códigos fragmentados descrevendo o exato mesmo fluxo de controle de vagas.

Nesse caso, a proximidade geométrica de tais códigos não é um simples acidente de jargão, mas, de fato, mostra que eles tratam da mesma logística de controle de vagas, substituições e atribuição de aulas de professores. Ao longo dos anos, provavelmente essa rotina foi sendo pulverizada em múltiplos códigos por diferentes gestores ou pequenas mudanças de nomenclatura administrativa.

3. CONCLUSÃO

O grande aprendizado dessa etapa é que a Inteligência Artificial não substitui o julgamento arquivístico, mas auxilia no processamento de milhares de documentos em segundos e entrega apenas as anomalias mais suspeitas. Cabe ao gestor logístico, munido da extração de termos-chave, dar o veredito final. Onde houver ilusão burocrática, ignora-se. Onde houver redundância real, estuda-se aplicar a fusão, simplificando a base de dados, otimizando o espaço físico e devolvendo agilidade e precisão à governança do arquivo.