

Métrica de Relevância de Códigos de Classificação Documental

Funcionamento, Fundamentos Matemáticos e Análise de Resultados

Autor: Vinicius Augusto de Souza

e-mail: va.vinicius@gmail.com

Data: 14 de agosto de 2026

Base de dados utilizada: 180.317 registros de tramitação processual (1960–2026)

Códigos analisados: 279 (259 com SCORE válido, 20 com TENDÊNCIA indefinida)

DOI: <https://doi.org/10.5281/zenodo.22014938>

Contents

1	Introdução e Motivação	3
1.1	Do Problema à Solução	3
2	Como a Métrica V8 Funciona	3
2.1	Visão Geral	3
2.2	Componente 1: ATIVIDADE	4
2.3	Componente 2: TENDÊNCIA	4
2.4	Categorização	5
3	Guia Prático para Gestores: Como Ler e Usar os Resultados	5
3.1	O que o SCORE significa	5
3.2	O que ATIVIDADE e TENDÊNCIA significam na prática	6
3.3	Como usar o ranking na tomada de decisão	6
3.4	Exemplo prático de leitura	7
4	Fundamentos Matemáticos	7
4.1	Ranking Percentilar	7
4.2	Inversão da Recência	8
4.3	Regressão Linear para Tendência	8
4.4	Ajuste de Confiança da Tendência	9
4.5	Fórmula do Score Final	9
5	Cálculos Realizados	10
5.1	Preparação dos Dados	10
5.2	Cálculo da ATIVIDADE	10
5.3	Cálculo da TENDÊNCIA	10
5.4	Cálculo do SCORE e Categorização	11
5.5	Resultados Globais	11
6	Hipóteses Assumidas	11
6.1	H1: Relevância = Atividade + Tendência	11
6.2	H2: História e Atualidade têm peso igual dentro de ATIVIDADE	12
6.3	H3: ATIVIDADE e TENDÊNCIA são independentes e têm peso igual	12
6.4	H4: Ranking percentilar é a normalização adequada	12
6.5	H5: A tendência de baixa confiança deve ser tratada como neutra	12
6.6	H6: Códigos com série degenerada geram TENDÊNCIA indefinida	12
6.7	H7: A janela de Volume Recente é de 5 anos	13
7	Exemplos de Cálculo Detalhados	13
7.1	Exemplo 1: Código 2.0.10.00.01 — O mais usado do sistema	13
7.2	Exemplo 2: Código 2.0.03.00.12 — Um código de baixa relevância	14
7.3	Exemplo 3: Código 1.0.06.02.02 — Tendência fortemente crescente	15
7.4	Exemplo 4: Código 5.3.02.01.59 — Tendência fortemente decrescente	16

7.5	Exemplo 5: Código 5.3.02.01.51 — O código “mediano”	16
8	Análise dos 10 Primeiros Códigos do Ranking	17
8.1	Padrões Observados	18
9	Resumo de Ações Prioritárias para Códigos Críticos	18
9.1	Ações Recomendadas	18
9.2	Alerta: 20 códigos com TENDÊNCIA indefinida (SCORE = NaN)	19
10	Diagnóstico de Robustez	20
10.1	Independência dos Componentes	20
10.2	Correlações Internas da ATIVIDADE	20
10.3	Sensibilidade a Pesos Alternativos	20
10.4	Confiança das Tendências	21
11	Conclusões	21
A	Código V8 Comentado	23

1 Introdução e Motivação

Gerenciar a logística de arquivamento físico de documentos e rastrear a ocupação de espaço é um desafio contínuo. Conforme o acervo cresce e milhares de caixas são processadas em lote, surge uma pergunta fundamental:

Quais códigos são realmente relevantes e merecem atenção prioritária de gestão?

Sem uma métrica objetiva, a resposta tende a depender de impressões subjetivas, vieses de memória recente ou do volume absoluto de processos — nenhum dos quais captura a complexidade da relevância real. Um código com 100.000 registros históricos mas em declínio acelerado é mais ou menos relevante que um com 200 registros em crescimento exponencial?

1.1 Do Problema à Solução

A dificuldade de responder a essa pergunta decorre da natureza multifacetada da relevância. Ela envolve tanto *o quanto* um código foi e está sendo usado (intensidade histórica e atual) quanto *para onde* o uso está indo (crescimento ou declínio). Tratar essas dimensões de forma separada e independente é o princípio central desta métrica.

A **Métrica V8** resolve o problema ao definir **dois componentes independentes**:

- **ATIVIDADE** — mede *o quanto* o código foi e está sendo usado, combinando 4 subcomponentes (Volume, Persistência, Volume Recente e Recência) em um único componente.
- **TENDÊNCIA** — mede *para onde* o uso está indo, via regressão linear anual ajustada por confiança (R^2).

A correlação entre ATIVIDADE e TENDÊNCIA é de $-0,094$ — praticamente zero — confirmando que os dois componentes medem dimensões genuinamente independentes. Nenhuma informação está sendo “contada duas vezes”.

O design de dois componentes garante que:

- Um código com muito uso histórico mas em declínio não é inflacionado — sua TENDÊNCIA negativa (se confiável) reduzirá o score.
- Um código com pouco uso histórico mas em crescimento será sinalizado — sua TENDÊNCIA positiva (se confiável) aumentará o score.
- Códigos com flutuações aleatórias (sem tendência estatisticamente significativa) recebem TENDÊNCIA neutra (≈ 50), evitando que ruído domine o resultado.

2 Como a Métrica V8 Funciona

2.1 Visão Geral

A V8 produz um **SCORE final** (0 a 100) para cada código, composto por dois componentes independentes:

$$\text{SCORE} = \frac{\text{ATIVIDADE} + \text{TENDÊNCIA}}{2} \quad (1)$$

- **ATIVIDADE** mede *o quanto* o código foi e está sendo usado.
- **TENDÊNCIA** mede *para onde* o uso está indo (crescendo, estável ou decrescendo).

Cada componente varia de 0 a 100. O peso é igual (50/50) porque não há justificativa empírica para privilegiar uma dimensão sobre a outra — cada uma captura algo genuinamente distinto.

2.2 Componente 1: ATIVIDADE

A ATIVIDADE é a **média de 4 subcomponentes**, cada um medindo uma faceta diferente da intensidade de uso:

Table 1: Subcomponentes da ATIVIDADE.

Subcomponente	O que mede	Lógica
Volume	Quantos registros no total	Quantidade absoluta de uso histórico
Persistência	Por quantos anos teve registros	Longevidade e regularidade do uso
Volume Recente (VR)	Registros nos últimos 5 anos	Intensidade de uso atual
Recência	Dias desde o último registro	O código ainda está “vivo”?

$$\text{ATIVIDADE} = \frac{\text{Volume}_P + \text{Persistência}_P + \text{VR}_P + \text{Recência}_P}{4} \quad (2)$$

O sufixo P indica que cada subcomponente é expresso em **percentil** (0 a 100) — i.e., a posição relativa do código na distribuição de todos os 279 códigos.

Note a estrutura implícita:

- **História** (Volume + Persistência) = peso 50% dentro de ATIVIDADE
- **Atualidade** (VR + Recência) = peso 50% dentro de ATIVIDADE

Isso equilibra o peso do passado e do presente, sem privilegiar nenhum dos dois.

2.3 Componente 2: TENDÊNCIA

A TENDÊNCIA captura a **direção do uso ao longo do tempo**, via regressão linear anual:

1. Conta-se quantos registros o código teve em cada ano.
2. Ajusta-se uma reta (regressão linear) a esses pontos.
3. O **slope** (inclinação) indica a taxa de variação percentual anual.
4. O R^2 (coeficiente de determinação) mede a confiança na tendência.
5. A TENDÊNCIA é mapeada para uma escala 0–100, centrada em 50 (neutro), com **ajuste por confiança**:

$$\text{TENDÊNCIA}_{\text{bruta}} = 50 + \text{slope_pct} \quad (\text{clipada em } [-50, +50]) \quad (3)$$

$$\text{TENDÊNCIA} = 50 + (\text{TENDÊNCIA}_{\text{bruta}} - 50) \times R^2 \quad (4)$$

O ajuste por R^2 é o mecanismo de honestidade da métrica: **tendências com baixa confiança (R^2 próximo de 0) colapsam para 50** (neutro), evitando que ruído estatístico inflacione ou deflate o score. **Ressalva:** R^2 bruto (não ajustado) tende a inflacionar com amostras pequenas — com $n = 3$ pontos, mesmo séries aleatórias podem produzir R^2 aparentemente elevado. Onde possível, recomenda-se complementar a interpretação com o p -valor do slope ou o R^2 ajustado (Seção 10.4).

2.4 Categorização

Após o cálculo do SCORE, cada código é classificado em uma categoria baseada na **posição percentil** do seu score na distribuição:

Table 2: Categorias de relevância e ações sugeridas.

Categoria	Critério	Ação sugerida
Crítica (Ação Imediata)	Percentil ≥ 90	Revisar com urgência
Alta Relevância	Percentil ≥ 70	Monitoramento próximo
Operacional Média	Percentil ≥ 30	Gestão rotineira
Baixa/Inativa	Percentil < 30	Pode ser desativado ou arquivado (após checagem com tabelas)

A categorização por percentis (e não por thresholds fixos) é **adaptativa**: ajusta-se automaticamente à distribuição real dos dados, sem limiares empíricos ou tetos absolutos. As únicas escolhas de design — janela de 5 anos, pesos 50/50, mínimo de 3 anos — são transparentes e de baixa sensibilidade (Seção 6).

Limitação nas fronteiras: As categorias criam cortes discretos numa distribuição contínua, o que pode gerar distorções limítrofes. Por exemplo, no topo da distribuição, a faixa Top 10% cobre scores de 71,05 a 74,73 — uma diferença inferior a 4 pontos que separa “Crítica” de “Alta Relevância”. Códigos próximos à fronteira (ex.: percentil 69,8 vs. 70,0) são estatisticamente indistinguíveis, mas recebem classificações e ações sugeridas diferentes. Recomenda-se que a interpretação priorize o *score contínuo* sobre a *categoria discreta*, especialmente para códigos próximos dos limiares.

3 Guia Prático para Gestores: Como Ler e Usar os Resultados

Esta seção destina-se a diretores e gestores que precisam *usar* os resultados da métrica na prática, sem necessariamente dominar os fundamentos matemáticos detalhados nas seções seguintes.

3.1 O que o SCORE significa

O SCORE é um número de 0 a 100 que resume a relevância de um código. **Não é uma nota de qualidade** — é uma medida de intensidade e direção do uso. Códigos com SCORE alto são

aqueles que mais demandam recursos de gestão (pessoal, espaço, atenção). Códigos com SCORE baixo são pouco usados ou inativos.

Como interpretar os valores:

- **SCORE ≥ 70 :** O código está entre os mais relevantes do sistema. Concentra a maior carga operacional e merece atenção prioritária.
- **SCORE entre 40 e 60:** O código tem relevância moderada. Gestão rotineira é suficiente.
- **SCORE < 40 :** O código é pouco usado ou inativo. Pode ser candidato a arquivamento ou desativação — mas **sempre** após verificação com as tabelas de temporalidade documental.

3.2 O que ATIVIDADE e TENDÊNCIA significam na prática

ATIVIDADE responde à pergunta: “Este código é muito ou pouco usado?” Ela combina:

- **Volume:** Quantos registros existem no total (desde os anos 1960).
- **Persistência:** Por quantos anos o código teve registros (longevidade).
- **Volume Recente:** Quantos registros nos últimos 5 anos (atualidade).
- **Recência:** Há quantos dias foi o último registro (o código ainda está “vivo”?).

Um código com ATIVIDADE alta é aquele que sempre foi muito usado e continua sendo. Um código com ATIVIDADE baixa pode ser inativo há anos ou ter volume histórico irrelevante.

TENDÊNCIA responde à pergunta: “O uso deste código está crescendo ou diminuindo?” Ela é calculada via regressão linear sobre os dados anuais e ajustada pela confiança estatística (R^2):

- **TENDÊNCIA > 50 :** O uso está crescendo (quanto mais acima de 50, mais forte o crescimento — se o R^2 for alto o suficiente para confirmar).
- **TENDÊNCIA ≈ 50 :** O uso está estável ou a tendência não é estatisticamente confiável.
- **TENDÊNCIA < 50 :** O uso está diminuindo (quanto mais abaixo de 50, mais forte o declínio — se o R^2 for alto o suficiente para confirmar).

3.3 Como usar o ranking na tomada de decisão

1. **Comece pelos Críticos:** Os 8 códigos na categoria “Crítica” (Top 10%) são a prioridade imediata. Eles concentram a maior demanda de gestão.
2. **Identifique tendências:** Para códigos com TENDÊNCIA > 51 e $R^2 > 0,10$, o crescimento é plausível — prepare recursos adicionais. Para códigos com TENDÊNCIA < 49 e $R^2 > 0,10$, o declínio é plausível — investigue causas e considere realocação de recursos.
3. **Não se preocupe com a maioria:** 69,9% dos códigos não têm tendência estatisticamente significativa ($R^2 < 0,10$). Para eles, a TENDÊNCIA é neutra (≈ 50) e o score é dominado pela ATIVIDADE. Isso não é um problema — é honestidade estatística.

4. **Sempre cruze com as tabelas de temporalidade:** Um código classificado como “Baixa/Inativa” pela métrica pode ter retenção obrigatória por determinação legal. A decisão de arquivamento *deve* ser validada com assessoria jurídica.
5. **Use o score contínuo, não apenas a categoria:** Códigos próximos a uma fronteira de categoria (ex.: SCORE 70,0 vs. 69,8) são estatisticamente equivalentes. Priorize o valor numérico.

3.4 Exemplo prático de leitura

Considere o código 2.0.10.00.01, o mais usado do sistema:

- SCORE = 74,73 (Crítica) — prioridade máxima.
- ATIVIDADE = 99,10 — está no topo absoluto de uso histórico e atual.
- TENDÊNCIA = 50,36 — praticamente neutra. O uso não está crescendo nem diminuindo de forma confiável.
- $R^2 = 0,109$ — baixo. A tendência positiva leve não é estatisticamente significativa.
- **Interpretação para o gestor:** Este código é um “gigante estável” — altíssima demanda de recursos, mas sem sinal de crescimento ou declínio. A prioridade é eficiência operacional (digitalização, automação, capacitação de servidores).

4 Fundamentos Matemáticos

4.1 Ranking Percentilar

Todos os subcomponentes são normalizados via **ranking percentilar**:

$$\text{percentil}(x) = \frac{\text{rank}(x)}{n} \times 100 \quad (5)$$

onde $\text{rank}(x)$ é a posição do valor x na ordenação crescente de todos os valores, e n é o número total de códigos (279).

Vantagens sobre normalização min-max ou z-score:

- **Robusto a outliers:** Um código com 123.826 registros não espreme os demais para a faixa 0–1.
- **Sem parâmetros:** Não exige escolha de limites ou desvios-padrão.
- **Distribuição uniforme:** Os percentis se distribuem uniformemente, facilitando a interpretação.
- **Invariante à escala:** O percentil 90 significa “melhor que 90% dos códigos”, independentemente dos valores absolutos.

Limitação: empates dissolvem o sinal de atividade zero. Na base analisada, ~40% dos códigos possuem Volume Recente = 0 registros nos últimos 5 anos. Todos recebem o mesmo percentil de VR (ex.: 36,56), independentemente de terem 0 ou 1 registro. Isso cria um “platô” no percentil que mascara diferenças reais — um código completamente inativo há décadas é indistinguível no VR de um que teve 1 registro no último ano. O ranking percentilar não distingue zero absoluto de quase-zero. Recomenda-se complementar a análise com os valores brutos quando se avalia códigos com atividade marginal.

4.2 Inversão da Recência

A recência bruta é “dias desde o último uso” — quanto menor, melhor. Para que valores maiores indiquem mais relevância, invertamos o ranking:

$$\text{Recência}_P = \left(1 - \frac{\text{rank}(\text{dias})}{n}\right) \times 100 \quad (6)$$

A conversão para percentil — em vez de uma escala linear de dias — garante que a punição seja proporcional à distribuição real dos dados. Suponha que a maioria dos códigos apresente inatividade entre 100 e 2.000 dias: um código com 30 dias de inatividade receberá nota muito alta (estará no topo do ranking), enquanto um com 8.000 dias ficará na base. Entre esses extremos, os códigos se distribuem suavemente. Isso significa que processos com gaps de poucas semanas **não** são punidos com o mesmo peso de processos abandonados há décadas — o percentil preserva granularidade onde os dados são densos e espaçamento onde são esparsos.

4.3 Regressão Linear para Tendência

Para cada código com ≥ 3 anos de dados, ajustamos uma regressão linear simples:

$$y_i = \alpha + \beta \cdot x_i \quad (7)$$

onde y_i é o número de registros no ano x_i , e β (slope) e α (intercepto) são estimados por mínimos quadrados:

$$\beta = \frac{\sum_i (x_i - \bar{x})(y_i - \bar{y})}{\sum_i (x_i - \bar{x})^2} \quad (8)$$

$$\alpha = \bar{y} - \beta \cdot \bar{x} \quad (9)$$

O **slope percentual** é calculado como:

$$\text{slope_pct} = \frac{\beta}{\bar{y}} \times 100 \quad (10)$$

normalizado pela média anual para permitir comparação entre códigos de volumes muito diferentes.

O R^2 (coeficiente de determinação) é:

$$R^2 = 1 - \frac{SS_{\text{res}}}{SS_{\text{tot}}} \quad (11)$$

onde SS_{res} é a soma dos quadrados dos resíduos e SS_{tot} é a soma total dos quadrados. R^2 varia de 0 (nenhuma tendência linear) a 1 (tendência perfeita).

4.4 Ajuste de Confiança da Tendência

O mecanismo central que torna a V8 honesta:

$$\text{TENDÊNCIA}_{\text{bruta}} = 50 + \text{clip}(\text{slope_pct}, -50, +50) \quad (12)$$

$$\text{TENDÊNCIA} = 50 + (\text{TENDÊNCIA}_{\text{bruta}} - 50) \times R^2 \quad (13)$$

Analisando os extremos:

- $R^2 = 1,0$ (confiança total): $\text{TENDÊNCIA} = \text{TENDÊNCIA}_{\text{bruta}}$. O slope é levado a sério.
- $R^2 = 0,5$ (confiança média): $\text{TENDÊNCIA} = 50 + (\text{TENDÊNCIA}_{\text{bruta}} - 50) \times 0,5$. O efeito é reduzido pela metade.
- $R^2 \rightarrow 0$ (sem confiança): $\text{TENDÊNCIA} \rightarrow 50$. O código recebe tendência neutra, independentemente do slope aparente.

Isso evita que códigos com flutuações aleatórias (slope alto por acidente, R^2 baixo) recebam scores injustificados.

4.5 Fórmula do Score Final

$$\text{SCORE} = \frac{\text{ATIVIDADE} + \text{TENDÊNCIA}}{2} \quad (14)$$

onde:

$$\text{ATIVIDADE} = \frac{\text{Volume}_P + \text{Persistência}_P + \text{VR}_P + \text{Recência}_P}{4} \quad (15)$$

$$\text{TENDÊNCIA} = 50 + \text{clip}(\text{slope_pct}, -50, +50) \times R^2 \quad (16)$$

O intervalo teórico do SCORE é:

- **Mínimo:** $(0 + 0)/2 = 0$ (código com zero atividade e tendência fortemente negativa com $R^2 = 1$)
- **Máximo:** $(100 + 100)/2 = 100$ (código com máxima atividade e tendência fortemente positiva com $R^2 = 1$)
- **Neutro:** $(50 + 50)/2 = 50$

Na prática, com 279 códigos reais, o intervalo observado foi **31,18 a 74,73**.

5 Cálculos Realizados

5.1 Preparação dos Dados

1. **Carregamento:** 180.317 registros brutos da base `gpp_consulta_formatada.xlsx`.
2. **Filtro temporal:** Mantidos apenas registros entre 1960 e 2026, removendo datas manifestamente inválidas (ex.: anos 8008, 2099).
3. **Agregação por código:** Para cada um dos 279 códigos, calculados:
 - `n_registros`: total de registros
 - `anos_ativos`: diferença entre data máxima e mínima, em anos
 - `vr_registros`: registros nos últimos 5 anos (2022–2026)
 - `dias_ultimo_uso`: dias desde o último registro até 14/08/2026

5.2 Cálculo da ATIVIDADE

Para cada código:

1. Volume_P = percentil de `n_registros` entre todos os códigos
2. Persistência_P = percentil de `anos_ativos`
3. VR_P = percentil de `vr_registros`
4. Recência_P = percentil invertido de `dias_ultimo_uso`
5. ATIVIDADE = média dos 4 percentis

5.3 Cálculo da TENDÊNCIA

Para cada código com ≥ 3 anos de dados:

1. Contagem de registros por ano
2. Regressão linear (mínimos quadrados) $\rightarrow$ slope, R^2
3. $\text{slope_pct} = (\text{slope}/\text{média_anual}) \times 100$, clipado em $[-50, +50]$
4. $\text{TENDÊNCIA} = 50 + \text{slope_pct} \times R^2$

Códigos com < 3 anos observados recebem $\text{TENDÊNCIA} = 50,00$ (neutra por definição) e SCORE válido. Isso afeta 61 códigos (21,9% do total), que são ancorados em tendência neutra por falta de série temporal suficiente para regressão.

Há ainda 20 códigos (7,2%) com ≥ 3 anos observados, porém $\text{TENDÊNCIA} = \text{NaN}$ e $\text{SCORE} = \text{NaN}$. A causa é que todos os seus registros estão distribuídos em anos diferentes, com exatamente 1 registro por ano — o que torna y_i constante (variância zero), impossibilitando o cálculo de R^2 pela função `linregress` do SciPy. Esses 20 códigos têm `vr_registros` = 0 e pouquíssimos registros (3 a 17), confirmando que são códigos marginalmente ativos. **Alternativa discutida:**

Uma abordagem mais inclusiva seria atribuir $TENDÊNCIA = 50$ com $R^2 = 0$ (confiança nula), colocando-os no ranking com SCORE dominado pela ATIVIDADE. A implementação atual opta por excluí-los para transparência, mas esta é uma escolha de implementação, não uma impossibilidade lógica (ver Seção 9.2).

5.4 Cálculo do SCORE e Categorização

1. $SCORE = (ATIVIDADE + TENDÊNCIA) / 2$
2. Categoria baseada na posição percentil do SCORE na distribuição dos 259 códigos válidos

5.5 Resultados Globais

Table 3: Estatísticas descritivas do SCORE final.

Estatística	Valor
Total de códigos	279
Com SCORE válido	259 (incluindo 61 com < 3 anos)
Com SCORE NaN	20 (regressão indefinida: y constante)
SCORE mínimo	31,18
SCORE máximo	74,73
SCORE médio	50,88
SCORE mediana	49,49
SCORE desvio-padrão	12,28
Quartil 25%	40,63
Quartil 50%	49,49
Quartil 75%	61,03
Quartil 90%	68,40

Table 4: Distribuição das categorias (259 códigos válidos).

Categoria	Quantidade	Percentual
Crítica (Ação Imediata)	8	3,1%
Alta Relevância	56	21,6%
Operacional Média	112	43,2%
Baixa/Inativa	83	32,0%

6 Hipóteses Assumidas

Toda métrica de relevância incorpora hipóteses. Explicitá-las é essencial para transparência e para que o gestor possa julgar a adequação dos resultados.

6.1 H1: Relevância = Atividade + Tendência

Hipótese: A relevância de um código documental é completamente descrita por duas dimensões: o quanto ele foi/está sendo usado (ATIVIDADE) e a direção temporal desse uso (TENDÊNCIA).

O que fica de fora: Qualquer dimensão qualitativa — como a importância jurídica, o valor histórico intrínseco, ou a criticidade operacional percebida pelos servidores. A métrica captura relevância *quantitativa* de uso, não relevância *substantiva* de conteúdo. **Alerta específico:** A métrica *não* captura obrigações legais ou normativas, como as **tabelas de temporalidade documental** que definem prazos de guarda e destinação. Um código classificado como “Baixa/Inativa” pela métrica pode ter retenção obrigatória por determinação legal — a decisão de desativação ou arquivamento *deve* ser cruzada com as tabelas de temporalidade e a assessoria jurídica, nunca baseada exclusivamente no SCORE.

6.2 H2: História e Atualidade têm peso igual dentro de ATIVIDADE

Hipótese: O passado (Volume + Persistência) e o presente (VR + Recência) contribuem igualmente para a ATIVIDADE (50% cada).

Justificativa: É um default honesto — sem razão empírica para privilegiar um sobre o outro. Se o gestor quiser enfatizar atualidade, pode ajustar os pesos internos de ATIVIDADE.

6.3 H3: ATIVIDADE e TENDÊNCIA são independentes e têm peso igual

Hipótese: Os dois componentes medem dimensões independentes e merecem peso igual no score final.

Validação empírica: A correlação $ATIVIDADE \times TENDÊNCIA$ é $-0,094$ (próxima de zero), confirmando independência estatística. Isso garante que nenhuma informação está sendo “contada duas vezes” — cada componente contribui com algo genuinamente distinto para o SCORE.

6.4 H4: Ranking percentilar é a normalização adequada

Hipótese: O percentil (posição relativa) é a melhor forma de normalizar subcomponentes com escalas e distribuições muito diferentes.

Justificativa: O volume de registros varia de 2 a 123.826 — uma faixa de 4 ordens de magnitude. Normalização min-max seria dominada por outliers; z-score seria afetada pela forte assimetria. O percentil é robusto a tudo isso.

6.5 H5: A tendência de baixa confiança deve ser tratada como neutra

Hipótese: Códigos com R^2 baixo ($< 0,10$) não têm tendência estatisticamente significativa e devem receber TENDÊNCIA próxima de 50 (neutro).

Validação empírica: **69,9% dos códigos** (181 de 259) têm $R^2 < 0,10$. Isso significa que a grande maioria dos códigos não apresenta tendência linear clara — seus dados são ruídosos, com flutuações irregulares. Ajustar por R^2 evita que o ruído domine o sinal.

6.6 H6: Códigos com série degenerada geram TENDÊNCIA indefinida

Hipótese: Códigos cuja série temporal é *degenerada* — todos os anos com a mesma contagem de registros (y_i constante, variância zero) — não permitem calcular R^2 , resultando em TENDÊNCIA = NaN e SCORE = NaN.

Impacto: 20 códigos (7,2% do total) recebem SCORE = NaN e são excluídos do ranking. Todos possuem ≥ 3 anos observados (3 a 17 anos), porém cada ano apresenta exatamente 1 registro, o que torna y_i constante e impede o cálculo de R^2 pela função `linregress` do SciPy. Esses 20 códigos também têm `vr_registros` = 0 (zero volume recente), confirmando que são marginalmente ativos. **Alternativa:** Atribuir TEND = 50 ($R^2 = 0$) seria internamente consistente — equivale a dizer “não há evidência de tendência, logo a contribuição é neutra”. Isso os manteria no ranking, com SCORE = ATIVIDADE/2, tipicamente baixo. A escolha atual (excluir) privilegia a transparência sobre a completude, mas ambas as abordagens são defensáveis.

Nota: Os 61 códigos com < 3 anos observados *não* são excluídos — recebem TENDÊNCIA = 50,00 (neutra por definição) e SCORE válido, sendo ancorados com tendência neutra por falta de série temporal suficiente para regressão.

6.7 H7: A janela de Volume Recente é de 5 anos

Hipótese: 5 anos (2022–2026) é a janela adequada para medir “atualidade” do uso.

Sensibilidade: Uma janela menor (3 anos) seria mais responsiva a mudanças recentes, mas mais vulnerável a flutuações. Uma janela maior (10 anos) seria mais estável, mas menos sensível a mudanças. 5 anos é um compromisso razoável.

7 Exemplos de Cálculo Detalhados

7.1 Exemplo 1: Código 2.0.10.00.01 — O mais usado do sistema

Dados brutos:

- 123.826 registros totais (o maior volume do sistema)
- 59,63 anos de vida (desde ~1966)
- 100 registros nos últimos 5 anos
- Último uso há 95 dias

Cálculo da ATIVIDADE:

Table 5: Cálculo da ATIVIDADE — Exemplo 1.

Subcomponente	Valor bruto	Percentil
Volume	123.826 registros	100,00
Persistência	59,63 anos	97,85
Volume Recente	100 registros	99,28
Recência	95 dias (invertido)	99,28

$$\text{ATIVIDADE} = \frac{100,00 + 97,85 + 99,28 + 99,28}{4} = 99,10$$

Cálculo da TENDÊNCIA:

- Regressão linear: slope = 3,28%/ano

- $R^2 = 0,109$ (confiança baixa — a série é muito ruidosa)
- $TENDÊNCIA = 50 + 3,28 \times 0,109 = \mathbf{50,36}$

O slope de +3,28% sugere leve crescimento, mas o R^2 de apenas 0,109 indica que a tendência é fraca — o ajuste por confiança colapsa quase todo o efeito para próximo de 50.

Score final:

$$SCORE = \frac{99,10 + 50,36}{2} = 74,73$$

Interpretação: Este código é o mais ativo do sistema ($ATIVIDADE = 99,10$), mas sua tendência é praticamente neutra ($TENDÊNCIA = 50,36$). O score alto vem quase inteiramente da $ATIVIDADE$. É um código “vital” — mas estável, não em ascensão.

7.2 Exemplo 2: Código 2.0.03.00.12 — Um código de baixa relevância

Dados brutos:

- 2 registros totais
- 1,00 ano de vida
- 0 registros nos últimos 5 anos
- Último uso há 7.896 dias ($\sim 21,6$ anos)

Cálculo da ATIVIDADE:

Table 6: Cálculo da ATIVIDADE — Exemplo 2.		
Subcomponente	Valor bruto	Percentil
Volume	2 registros	14,34
Persistência	1,00 ano	15,77
Volume Recente	0 registros	36,56
Recência	7.896 dias (inv.)	12,54

$$ATIVIDADE = \frac{14,34 + 15,77 + 36,56 + 12,54}{4} = 19,80$$

Note que o $VR_P = 36,56$ mesmo com 0 registros. Isso acontece porque muitos códigos também têm 0 registros recentes — o percentil reflete a posição na distribuição, não o valor absoluto. **Atenção:** este é um caso emblemático da limitação discutida na Seção 4 — com $\sim 40\%$ dos códigos tendo $VR = 0$, todos os zeros recebem o *mesmo* percentil (36,56), criando um “platô” que mascara diferenças entre inatividade total e atividade marginal. Um código com 1 registro recente receberia percentil semelhante ou marginalmente superior, sem distinção significativa. Recomenda-se checar os valores brutos antes de interpretar códigos nesta faixa.

Cálculo da TENDÊNCIA:

- Apenas 2 anos observados (< 3 anos mínimo)
- $TENDÊNCIA = 50,00$ (neutro por definição — dados insuficientes)

- $R^2 = 0,000$

Score final:

$$\text{SCORE} = \frac{19,80 + 50,00}{2} = 34,90$$

Interpretação: ATIVIDADE muito baixa (19,80), TENDÊNCIA neutra por falta de dados. Score no terço inferior. Provável candidato a desativação ou arquivamento.

7.3 Exemplo 3: Código 1.0.06.02.02 — Tendência fortemente crescente

Dados brutos:

- 5 registros totais
- 3,06 anos de vida
- 0 registros nos últimos 5 anos
- Último uso há 8.654 dias ($\sim 23,7$ anos)

Cálculo da ATIVIDADE:

Table 7: Cálculo da ATIVIDADE — Exemplo 3.

Subcomponente	Valor bruto	Percentil
Volume	5 registros	27,24
Persistência	3,06 anos	19,71
Volume Recente	0 registros	36,56
Recência	8.654 dias (inv.)	7,17

$$\text{ATIVIDADE} = \frac{27,24 + 19,71 + 36,56 + 7,17}{4} = 22,67$$

Cálculo da TENDÊNCIA:

- Regressão linear: slope = $+42,86\%$ /ano
- $R^2 = 0,893$ (confiança alta!)
- $\text{TENDÊNCIA}_{\text{bruta}} = 50 + 42,86 = 92,86$
- $\text{TENDÊNCIA} = 50 + (92,86 - 50) \times 0,893 = \mathbf{88,27}$

Score final:

$$\text{SCORE} = \frac{22,67 + 88,27}{2} = 55,47$$

Interpretação: ATIVIDADE baixa (22,67), mas TENDÊNCIA muito alta (88,27) — o código está em clara ascensão. O score de 55,47 reflete esse equilíbrio: o código ainda é pequeno em volume absoluto, mas a trajetória é inequívoca. Uma métrica que só olhasse volume ignoraria este sinal; a V8 o captura.

Caveat: Este exemplo tem apenas $n = 3$ pontos na série temporal. Embora $R^2 = 0,893$ seja numericamente elevado, ele é bruto (não ajustado) e deve ser interpretado com cautela

— com 3 pontos, até séries aleatorizadas podem gerar R^2 aparentemente alto. Recomenda-se complementar com o p -valor do slope (Seção 10.4).

7.4 Exemplo 4: Código 5.3.02.01.59 — Tendência fortemente decrescente

Dados brutos:

- 94 registros totais
- 12,99 anos de vida
- 0 registros nos últimos 5 anos
- Último uso há 4.610 dias ($\sim 12,6$ anos)

Cálculo da ATIVIDADE:

Table 8: Cálculo da ATIVIDADE — Exemplo 4.

Subcomponente	Valor bruto	Percentil
Volume	94 registros	70,61
Persistência	12,99 anos	36,20
Volume Recente	0 registros	36,56
Recência	4.610 dias (inv.)	41,94

$$\text{ATIVIDADE} = \frac{70,61 + 36,20 + 36,56 + 41,94}{4} = 46,33$$

Cálculo da TENDÊNCIA:

- Regressão linear: slope = $-19,01\%$ /ano
- $R^2 = 0,849$ (confiança alta)
- $\text{TENDÊNCIA}_{\text{bruta}} = 50 + (-19,01) = 30,99$
- $\text{TENDÊNCIA} = 50 + (30,99 - 50) \times 0,849 = \mathbf{33,85}$

Score final:

$$\text{SCORE} = \frac{46,33 + 33,85}{2} = 40,09$$

Interpretação: ATIVIDADE mediana (46,33), mas TENDÊNCIA claramente negativa (33,85). O código teve uso moderado no passado, mas está em declínio confirmado. O score de 40,09 reflete essa deterioração — está na faixa de “Baixa/Inativa”.

7.5 Exemplo 5: Código 5.3.02.01.51 — O código “mediano”

Dados brutos:

- 95 registros totais
- 16,99 anos de vida

- 0 registros nos últimos 5 anos
- Último uso há 4.610 dias

Cálculo da ATIVIDADE:

Table 9: Cálculo da ATIVIDADE — Exemplo 5.

Subcomponente	Valor bruto	Percentil
Volume	95 registros	71,15
Persistência	16,99 anos	43,91
Volume Recente	0 registros	36,56
Recência	4.610 dias (inv.)	41,94

$$\text{ATIVIDADE} = \frac{71,15 + 43,91 + 36,56 + 41,94}{4} = 48,39$$

Cálculo da TENDÊNCIA:

- slope = $-4,23\%/ano$
- $R^2 = 0,076$ (confiança baixa)
- $TENDÊNCIA = 50 + (-4,23) \times 0,076 = 49,68$

Score final:

$$\text{SCORE} = \frac{48,39 + 49,68}{2} = 49,03$$

Interpretação: ATIVIDADE mediana, TENDÊNCIA neutra (o R^2 baixo colapsa o slope para próximo de 50). Score de 49,03 — praticamente no centro da distribuição. Este é o código “típico”: uso moderado, sem tendência clara.

8 Análise dos 10 Primeiros Códigos do Ranking

Table 10: Top 10 códigos mais relevantes segundo a métrica V8.

#	Código	Score	Ativ.	Tend.	slope%/a	R^2	Categoria
1	2.0.10.00.01	74,73	99,10	50,36	+3,28	0,109	Crítica
2	5.3.02.01.12	74,67	98,03	51,31	+5,23	0,251	Crítica
3	2.0.10.00.23	74,00	97,45	50,56	+3,26	0,173	Crítica
4	2.0.01.05.04	72,70	95,43	49,96	-2,67	0,013	Crítica
5	5.3.03.00.10	72,22	94,22	50,23	+2,64	0,086	Crítica
6	5.3.05.00.04	72,16	94,31	50,02	+0,93	0,021	Crítica
7	5.3.02.01.23	71,86	93,06	50,66	+2,85	0,232	Crítica
8	5.3.02.01.04	71,10	92,20	50,00	-0,23	0,000	Crítica
9	1.0.06.01.05	71,08	92,43	49,74	-2,45	0,108	Alta
10	5.3.02.01.25	71,05	91,62	50,47	+2,73	0,172	Alta

8.1 Padrões Observados

1. Dominância da ATIVIDADE. Os 10 primeiros códigos têm ATIVIDADE entre 91,62 e 99,10 — todos no topo absoluto da distribuição de atividade. A TENDÊNCIA varia apenas de 49,74 a 51,31, ou seja, todos estão praticamente neutros. Isso revela um padrão claro: **no topo do ranking, o que importa é a ATIVIDADE**. A TENDÊNCIA só faz diferença significativa mais abaixo, onde a variação de ATIVIDADE é menor.

2. Baixa confiança nas tendências. Dos 10 códigos do Top 10, apenas 2 têm $R^2 > 0,10$ (5.3.02.01.12 com 0,251 e 5.3.02.01.23 com 0,232). Os demais têm $R^2 < 0,11$ — tendências estatisticamente desprezíveis. Isso é esperado: códigos de alto volume tendem a ter flutuações irregulares ano a ano, dificultando a detecção de tendências lineares.

3. Perfis distintos:

- 2.0.10.00.01 (123.826 registros, 60 anos): O gigante do sistema. ATIVIDADE = 99,10. Sua categoria “Crítica” não indica perigo, mas **proeminência** — é o código que mais demanda recursos de gestão.
- 5.3.02.01.12 (1.224 registros, 64 anos): Volume modesto, mas persistência extraordinária. Seu slope de +5,23%/ano com $R^2 = 0,251$ é a tendência mais confiável do Top 10 — leve ascensão.
- 2.0.01.05.04 (4.814 registros, 51 anos): slope negativo (−2,67%), mas $R^2 = 0,013$ — a tendência negativa é estatisticamente insignificante. Na prática, é estável.
- 5.3.02.01.04 (392 registros, 46 anos): slope quase zero (−0,23%), $R^2 = 0,000$ — a definição de “estável”. No ranking por pura ATIVIDADE.

4. História vs. Atualidade: Todos os 8 códigos Críticos têm alta pontuação tanto em Volume/Persistência (história) quanto em VR/Recência (atualidade) — são códigos que sempre foram muito usados e continuam sendo. Não há “dinossauros” (muito uso histórico, zero atual) entre os Críticos.

9 Resumo de Ações Prioritárias para Códigos Críticos

Os 8 códigos na categoria Crítica (percentil ≥ 90 do SCORE) são os que mais demandam atenção de gestão. Abaixo, um diagnóstico individualizado:

9.1 Ações Recomendadas

Para todos os 8 códigos Críticos:

1. **Revisão documental prioritária:** Verificar se a classificação está correta, se há necessidade de subdivisão e se as regras de temporalidade estão adequadas.
2. **Monitoramento contínuo:** Estes códigos concentram a maior carga operacional — qualquer problema aqui tem impacto desproporcional.

Table 11: Diagnóstico dos 8 códigos Críticos.

#	Código	Score	Ativ.	Tend.	slope%	R^2	Diagnóstico
1	2.0.10.00.01	74,73	99,10	50,36	+3,3	0,11	Gigante estável
2	5.3.02.01.12	74,67	98,03	51,31	+5,2	0,25	Persistente em leve ascensão
3	2.0.10.00.23	74,00	97,45	50,56	+3,3	0,17	Alto volume, tendência fraca
4	2.0.01.05.04	72,70	95,43	49,96	-2,7	0,01	Alto volume, aparentemente estável
5	5.3.03.00.10	72,22	94,22	50,23	+2,6	0,09	Persistente, tendência incerta
6	5.3.05.00.04	72,16	94,31	50,02	+0,9	0,02	Estável — sem tendência clara
7	5.3.02.01.23	71,86	93,06	50,66	+2,9	0,23	Persistente em leve ascensão
8	5.3.02.01.04	71,10	92,20	50,00	-0,2	0,00	Totalmente estável

3. **Capacitação de servidores:** Garantir que as equipes conheçam bem os critérios de classificação para estes códigos, reduzindo erros de tramitação.

Ações específicas por perfil:

- **Gigantes estáveis** (2.0.10.00.01, 2.0.10.00.23): O volume é tão alto (123.826 e 13.042 registros) que a prioridade é eficiência operacional — digitalização, automação de indexação, fluxos de trabalho simplificados.
- **Em ascensão confirmada** (5.3.02.01.12, 5.3.02.01.23): Slope positivo com R^2 razoável (0,25 e 0,23). Preparar-se para aumento de demanda. Considerar antecipar recursos e regras de escala.
- **Aparentemente estáveis** (2.0.01.05.04, 5.3.02.01.04, 5.3.05.00.04): R^2 muito baixo — não há evidência de mudança. Manter o status quo, mas monitorar anualmente.
- **Tendência incerta** (5.3.03.00.10): Slope positivo mas $R^2 = 0,09$ — insuficiente para confirmar crescimento. Ação: coletar mais dados antes de decidir.

9.2 Alerta: 20 códigos com TENDÊNCIA indefinida (SCORE = NaN)

20 códigos (7,2% do total) ficaram com SCORE = NaN e foram excluídos do ranking. A causa *não* é a falta de anos observados — todos possuem ≥ 3 anos (3 a 17). A causa é que a série temporal é *degenerada*: cada ano contém exatamente 1 registro, resultando em y_i constante (variância zero). Isso impede o cálculo de R^2 pela função `linregress` do SciPy, que retorna `r_value = NaN`, tornando TENDÊNCIA e SCORE indefinidos. Todos os 20 códigos também têm `vr_registros = 0` (zero volume recente), confirmando que são marginalmente ativos. Recomendação: **monitorar por mais 1–2 anos**; se a contagem por ano se diferenciar (mais de 1 registro em algum ano), o cálculo passará a ser viável.

Alternativa de implementação: Uma solução mais coerente com a lógica da métrica seria atribuir TENDÊNCIA = 50 com $R^2 = 0$ — ou seja, “não há evidência estatística de tendência, portanto a contribuição é neutra”. Isso manteria os 20 códigos no ranking, com SCORE =

ATIVIDADE/2 (tipicamente muito baixo, dado que todos têm ATIVIDADE reduzida). A abordagem atual (excluir) é mais conservadora e transparente, mas a alternativa é internamente consistente e pode ser preferida em contextos que exigem cobertura completa do universo de códigos.

10 Diagnóstico de Robustez

10.1 Independência dos Componentes

A correlação entre ATIVIDADE e TENDÊNCIA é $-0,094$ — praticamente zero. Isso confirma que os dois componentes medem dimensões genuinamente independentes. Nenhuma informação está sendo “contada duas vezes”.

10.2 Correlações Internas da ATIVIDADE

Table 12: Correlações entre os subcomponentes da ATIVIDADE.

Par	Correlação
Volume $\times$ Persistência	0,845
Persistência $\times$ Recência	0,767
VR $\times$ Recência	0,785
Volume $\times$ Recência	0,693
Persistência $\times$ VR	0,603
Volume $\times$ VR	0,531

A correlação mais alta é **Volume $\times$ Persistência = 0,845**. Isso é esperado: códigos com mais registros tendem a ter mais anos de uso. As demais correlações são moderadas, indicando que os 4 subcomponentes capturam facetas distintas mas não completamente independentes — o que é inevitável quando todos medem aspectos do mesmo fenômeno (uso do código).

Nota de transparência: A correlação Volume $\times$ Persistência (0,845) indica multicolinearidade *intracomponente* considerável. Isso é uma limitação real: embora ATIVIDADE e TENDÊNCIA sejam independentes ($-0,094$), a redundância entre os subcomponentes de ATIVIDADE persiste. Se desejado, poderia-se reduzir para 3 subcomponentes (ex.: fundir Volume e Persistência, ou aplicar PCA). No entanto, manter os 4 subcomponentes explícitos facilita a interpretação e a comunicação com gestores, e não impacta diretamente o SCORE final, pois os subcomponentes são combinados antes da normalização percentilar.

10.3 Sensibilidade a Pesos Alternativos

A V8 usa pesos iguais (50% ATIVIDADE, 50% TENDÊNCIA). Mas o que aconteceria com pesos diferentes?

Interpretação:

- A correlação é sempre $> 0,98$ — o ranking é muito estável independentemente dos pesos.
- O deslocamento máximo de 94 posições (no cenário extremo Ativ 30/Tend 70) afeta códigos de baixo e médio score, não o Top 10.

Table 13: Sensibilidade do ranking a pesos alternativos.

Configuração	Correlação com ranking base	Deslocamento máx.
Ativ 70% / Tend 30%	0,9956	77 posições
Ativ 60% / Tend 40%	0,9986	35 posições
Ativ 30% / Tend 70%	0,9866	94 posições

- Pesos 60/40 causam mudanças mínimas ($\text{corr} = 0,9986$, $\text{shift} = 35$).

Conclusão: A escolha 50/50 é robusta. Mesmo que o gestor prefira dar mais peso à ATIVIDADE (mais intuitivo), o ranking muda pouco.

10.4 Confiança das Tendências

- **69,9% dos códigos** (181 de 259) têm $R^2 < 0,10$ — tendência essencialmente nula.
- Apenas **30,1%** (78 códigos) têm $R^2 \geq 0,10$ — tendência com alguma confiabilidade.
- Apenas **7,3%** (19 códigos) têm $R^2 \geq 0,50$ — tendência confiável.

Isso significa que, para a maioria dos códigos, a TENDÊNCIA contribui com quase nada além de 50 (neutro). O score final é dominado pela ATIVIDADE. A TENDÊNCIA só se torna discriminante para códigos com tendências fortes e bem estabelecidas — exatamente como deveria ser.

Limitação estatística do R^2 bruto: O ajuste por R^2 utiliza o coeficiente *bruto* (não ajustado), que é sensível ao tamanho da amostra. Com o mínimo de $n = 3$ pontos, o R^2 pode ser inflacionado por acaso — um R^2 de 0,50 com $n = 3$ é consideravelmente menos impressionante do que o mesmo valor com $n = 10$. Recomenda-se complementar a interpretação com o p -valor do slope ou o R^2 ajustado ($\bar{R}^2 = 1 - (1 - R^2) \frac{n-1}{n-2}$), especialmente para códigos com poucos anos observados.

Sobre o peso 50/50: A distribuição de pesos iguais entre ATIVIDADE e TENDÊNCIA é uma escolha de *simplicidade*, não empiricamente calibrada. Dado que 69,9% dos códigos têm $R^2 < 0,10$, a TENDÊNCIA efetivamente contribui pouco para a maioria dos scores — o que significa que, na prática, a ATIVIDADE já domina o resultado independentemente do peso formal. A análise de sensibilidade (Seção 10) confirma que mudar para 60/40 ou 70/30 tem impacto mínimo na ordenação ($\rho > 0,99$), o que reforça que o peso exato é pouco relevante para o ranking, mas deve ser reconhecido como uma escolha paramétrica, não como ausência de escolha.

11 Conclusões

1. **ATIVIDADE e TENDÊNCIA são componentes independentes:** a correlação entre eles é $-0,094$ (praticamente zero), garantindo que cada componente contribui com informação genuinamente distinta. Multicolinearidade intracomponente ($\text{Volume} \times \text{Persistência} = 0,845$) persiste e é reconhecida como limitação (Seção 10).

2. **A métrica é honesta:** Códigos sem tendência estatisticamente significativa recebem TENDÊNCIA próxima de 50, não inflacionada por ruído. O ajuste por R^2 é o mecanismo que garante isso.
3. **A categorização é adaptativa:** Os limites entre categorias são definidos pelos próprios dados (percentis da distribuição), não por thresholds fixos que poderiam ser arbitrários ou desatualizados.
4. **Parâmetros mínimos e transparentes:** A normalização por percentis elimina a necessidade de limiares absolutos. No entanto, a métrica *não* é livre de parâmetros — as escolhas de design restantes são parâmetros de fato: janela VR de 5 anos, pesos 50/50, mínimo de 3 anos (`min_anos`) e o uso de R^2 bruto (não ajustado). Todas são transparentes, justificadas na Seção 6 e de baixa sensibilidade comprovada (Seção 10), mas devem ser reconhecidas como *escolhas paramétricas*, não como ausência de parâmetros.
5. **O ranking é robusto:** Alterar os pesos de ATIVIDADE/TENDÊNCIA de 50/50 para 60/40 ou 70/30 muda muito pouco a ordenação (correlação $> 0,99$).
6. **ATIVIDADE domina o topo:** Os códigos mais relevantes são aqueles com maior atividade histórica e atual. A TENDÊNCIA é mais discriminante no meio e no fundo do ranking — onde a variação de ATIVIDADE é menor.
7. **8 códigos são Críticos:** Eles representam 3,1% dos códigos e concentram a maior demanda de gestão. Nenhum está em declínio confirmado — todos são estáveis ou em leve ascensão.
8. **70% dos códigos não têm tendência clara:** Isso não é um problema da métrica — é um fato dos dados. A maioria dos códigos tem flutuações irregulares sem direção linear definida.
9. **20 códigos ficaram sem score:** Séries temporais degeneradas (≥ 3 anos observados, porém y_i constante — variância zero — impossibilitando o cálculo de R^2). Todos têm `vr_registros` = 0. Devem ser monitorados e reavaliados quando a contagem por ano se diferenciar. **Alternativa discutida:** atribuir $TEND = 50$ ($R^2 = 0$) manteria esses códigos no ranking com $SCORE = ATIVIDADE/2$ (Seção 9.2).
10. **A métrica é uma ferramenta prática para gestão baseada em dados:** Os gestores agora têm uma ferramenta quantitativa, transparente e validada para priorizar ações de organização documental (ver Seção 3 para orientações práticas de uso).

A Código V8 Comentado

O código abaixo é autocontido e pronto para execução no Google Colab ou em qualquer ambiente Python com as bibliotecas `pandas`, `numpy`, `scipy` e `matplotlib`.

Listing 1: Métrica V8 — Código completo para Google Colab

```

1  """
2  METRICA V8 -- RELEVANCIA GPP (Guarda Permanente de Processos)
3  Autor: OreateAI
4  Data: 14/08/2026
5  Versao: 8.0 (2 componentes: ATIVIDADE + TENDENCIA)
6
7  COMO USAR NO GOOGLE COLAB:
8  1. Faça upload do arquivo Excel (.xlsx) com as colunas: COD, DATA, DESC_SETOR
9  2. Ajuste a variavel FILE_PATH abaixo para o caminho do seu arquivo
10 3. Rode celula por celula (ou execute tudo de uma vez)
114. Os resultados (CSV + Excel + graficos) serao salvos automaticamente
12
13 PRINCIPIOS:
14 - 2 componentes independentes (ATIVIDADE + TENDENCIA)
15 - ATIVIDADE tem 4 subcomponentes (Volume, Persistencia, VR, Recencia)
16 - Categorizacao por percentis da distribuicao (sem thresholds fixos)
17 - Zero parametros arbitrarios (usa percentis dos proprios dados)
18 - Explicacao passo a passo embutida nos prints
19 - Exporta CSV e Excel (.xlsx)
20
21 COMPONENTES:
22 - ATIVIDADE = Volume + Persistencia + VR (Volume Recente) + Recencia
23 - TENDENCIA = Regressao linear anual (slope) ajustada por R2
24 - SCORE = 0.50 * ATIVIDADE + 0.50 * TENDENCIA
25 - Correlacao ATIVIDADE x TENDENCIA: -0.094 (independentes)
26 """
27
28 # =====
29 # 0. CONFIGURACOES INICIAIS
30 # =====
31
32 # --- AJUSTE ESTE CAMINHO PARA O SEU ARQUIVO NO COLAB ---
33 FILE_PATH = '/content/gpp_Consulta_Formatada.xlsx'
34
35 # Data de referencia ("hoje") para calcular recencia
36 HOJE = pd.Timestamp('2026-08-14')
37
38 # Janela de anos para calcular Volume Recente (subcomponente de ATIVIDADE)
39 JANELA_VR_ANOS = 5
40
41 # =====
42 # 1. IMPORTACOES
43 # =====
44
45 import pandas as pd
46 import numpy as np
47 import matplotlib.pyplot as plt
48 from scipy.stats import linregress
49 import warnings
50 warnings.filterwarnings('ignore')
51
52 print("=" * 70)
53 print("V8 -- METRICA DE RELEVANCIA GPP (2 Componentes)")

```



```

54 print("=" * 70)
55 print("\n[INFO] Bibliotecas carregadas com sucesso.")
56
57 # =====
58 # 2. CARREGAMENTO DOS DADOS
59 # =====
60
61 print("\n" + "=" * 70)
62 print("ETAPA 1: CARREGAMENTO DOS DADOS")
63 print("=" * 70)
64
65 df = pd.read_excel(FILE_PATH, engine='openpyxl')
66 print(f"[OK] Arquivo carregado: {FILE_PATH}")
67 print(f"      Linhas brutas: {len(df):,}")
68 print(f"      Colunas: {list(df.columns)}")
69
70 df['DATA'] = pd.to_datetime(df['DATA'], errors='coerce', dayfirst=True)
71
72 ano = df['DATA'].dt.year
73 df = df[(ano >= 1960) & (ano <= 2026)].copy()
74
75 print(f"\n[INFO] Apos filtro de datas validas (1960-2026):")
76 print(f"      Registros validos: {len(df):,}")
77 print(f"      Período: {df['DATA'].min().date()} a {df['DATA'].max().date()}")
78
79 # =====
80 # 3. AGREGACAO POR CODIGO
81 # =====
82
83 print("\n" + "=" * 70)
84 print("ETAPA 2: ESTATISTICAS POR CODIGO")
85 print("=" * 70)
86
87 ano_inicio_vr = HOJE.year - JANELA_VR_ANOS + 1
88
89 stats = df.groupby('COD').agg(
90     n_registros=('DATA', 'size'),
91     n_setores=('DESC_SETOR', 'nunique'),
92     data_min=('DATA', 'min'),
93     data_max=('DATA', 'max'),
94     ultima_data=('DATA', 'max'),
95 ).reset_index()
96
97 # Volume Recente: registros nos ultimos JANELA_VR_ANOS anos
98 vr_list = []
99 for codigo in stats['COD']:
100     anos_cod = df[df['COD'] == codigo]['DATA'].dt.year
101     vr = (anos_cod >= ano_inicio_vr).sum()
102     vr_list.append(vr)
103 stats['vr_registros'] = vr_list
104
105 # Recencia: dias desde o ultimo uso
106 stats['dias_ultimo_uso'] = (HOJE - stats['ultima_data']).dt.days
107 stats['dias_ultimo_uso'] = stats['dias_ultimo_uso'].clip(lower=0)
108
109 # Persistencia: amplitude temporal em anos
110 stats['anos_ativos'] = (stats['data_max'] - stats['data_min']).dt.days / 365.25
111 stats['anos_ativos'] = stats['anos_ativos'].clip(lower=0)
112
113 n_codigos = len(stats)
114 print(f"[OK] Codigos unicos encontrados: {n_codigos}")

```

```

115 print(f"      Exemplos de codigos: {'', '.join(stats['COD'].head(5).tolist())}")
116 print(f"      Volume Recente calculado para janela: {ano_inicio_vr}-{HOJE.year}
      ({JANELA_VR_ANOS} anos)")
117
118 # =====
119 # 4. COMPONENTE 1: ATIVIDADE (4 subcomponentes)
120 # =====
121
122 print("\n" + "=" * 70)
123 print("ETAPA 3: COMPONENTE 1 -- ATIVIDADE (4 subcomponentes)")
124 print("=" * 70)
125 print("O que mede: O quanto este codigo foi usado, por quanto tempo,")
126 print("      com que intensidade recente, e se ainda e usado.")
127 print("")
128 print("Subcomponentes:")
129 print("  Volume      -> Quantos registros no total (historia)")
130 print("  Persistencia -> Por quantos anos teve registros (longevidade)")
131 print("  Vol. Recente  -> Registros nos ultimos 5 anos (intensidade atual)")
132 print("  Recencia      -> Dias desde o ultimo uso (esta vivo ou morto?)")
133 print("")
134
135 # 4a. Volume percentil
136 stats['volume_percentil'] = stats['n_registros'].rank(pct=True) * 100
137
138 # 4b. Persistencia percentil
139 stats['persistencia_percentil'] = stats['anos_ativos'].rank(pct=True) * 100
140
141 # 4c. Volume Recente percentil
142 stats['vr_percentil'] = stats['vr_registros'].rank(pct=True) * 100
143
144 # 4d. Recencia percentil (invertido: menos dias = mais recente = mais relevante)
145 stats['recencia_percentil'] = (1 - stats['dias_ultimo_uso'].rank(pct=True)) * 100
146
147 # 4e. ATIVIDADE = media dos 4 subcomponentes
148 stats['ATIVIDADE'] = (
149     stats['volume_percentil'] +
150     stats['persistencia_percentil'] +
151     stats['vr_percentil'] +
152     stats['recencia_percentil']
153 ) / 4
154
155 # Exemplo detalhado
156 cod_ex = stats.nlargest(1, 'n_registros').iloc[0]
157 print("Calculo passo a passo (exemplo: codigo mais usado):")
158 print(f" a) Volume bruto = {cod_ex['n_registros'],} registros")
159 print(f" b) Volume percentil = {cod_ex['volume_percentil']:.1f}")
160 print(f" c) Persistencia bruta = {cod_ex['anos_ativos']:.1f} anos")
161 print(f" d) Persistencia percentil = {cod_ex['persistencia_percentil']:.1f}")
162 print(f" e) Volume Recente (ultimos {JANELA_VR_ANOS} anos) =
      {cod_ex['vr_registros'],} registros")
163 print(f" f) Volume Recente percentil = {cod_ex['vr_percentil']:.1f}")
164 print(f" g) Dias desde ultimo uso = {cod_ex['dias_ultimo_uso']} dias")
165 print(f" h) Recencia percentil = {cod_ex['recencia_percentil']:.1f}")
166 ativ_calc = (cod_ex['volume_percentil'] + cod_ex['persistencia_percentil'] +
167             cod_ex['vr_percentil'] + cod_ex['recencia_percentil']) / 4
168 print(f" i) ATIVIDADE = ({cod_ex['volume_percentil']:.1f} + "
169     f"{cod_ex['persistencia_percentil']:.1f} + {cod_ex['vr_percentil']:.1f} + "
170     f"{cod_ex['recencia_percentil']:.1f}) / 4 = {ativ_calc:.1f}")
171
172 # =====
173 # 5. COMPONENTE 2: TENDENCIA

```

```

174 # =====
175
176 print("\n" + "=" * 70)
177 print("ETAPA 4: COMPONENTE 2 -- TENDENCIA")
178 print("=" * 70)
179 print("O que mede: O uso do código esta crescendo ou diminuindo?")
180 print("Regressao linear anual, ajustada por R2 (confiabilidade estatistica).")
181 print("")
182
183 def calcular_tendencia(codigo):
184     """
185     Calcula tendencia com regressao linear anual.
186
187     Passos:
188     1. Conta registros por ano
189     2. Ajusta reta (minimos quadrados)
190     3. Slope % = variacao percentual anual relativa a media
191     4. Tendencia bruta = 50 + slope_pct (clipado em [-50, +50])
192     5. Tendencia ajustada = 50 + (Tendencia_bruta - 50) * R2
193        -> R2 baixo colapsa para 50 (neutro)
194        -> R2 alto preserva o efeito do slope
195
196     Retorna: (tendencia_ajustada, n_anos_obs, slope_pct, R2, confianca)
197     """
198     anos = df[df['COD'] == codigo]['DATA'].dt.year.value_counts().sort_index()
199
200     # Menos de 3 anos: dados insuficientes
201     if len(anos) < 3:
202         return 50.0, len(anos), 0.0, 0.0, 0.0
203
204     x = anos.index.values.astype(float)
205     y = anos.values.astype(float)
206
207     # Regressao linear
208     slope, intercept, r_value, _, _ = linregress(x, y)
209     r2 = r_value ** 2
210
211     # Slope percentual (normalizado pela media)
212     media = y.mean() if y.mean() > 0 else 1.0
213     slope_pct = (slope / media) * 100
214     slope_pct = np.clip(slope_pct, -50, 50) # Teto de +-50%
215
216     # Tendencia bruta e ajustada por confianca
217     tendencia_bruta = 50 + slope_pct
218     confianca = r2
219     tendencia_ajustada = 50 + (tendencia_bruta - 50) * confianca
220
221     return tendencia_ajustada, len(anos), slope_pct, r2, confianca
222
223 # Calcula tendencia para todos os codigos
224 tendencias = []
225 for _, row in stats.iterrows():
226     t, n_anos, slope, r2, conf = calcular_tendencia(row['COD'])
227     tendencias.append({
228         'COD': row['COD'],
229         'TENDENCIA': t,
230         'n_anos_obs': n_anos,
231         'slope_pct': slope,
232         'R2': r2,
233         'confianca': conf
234     })

```

```

235
236 tend_df = pd.DataFrame(tendencias)
237 stats = stats.merge(tend_df, on='COD')
238
239 # Exemplo
240 cod_tend = stats.nlargest(1, 'n_registros').iloc[0]
241 print("Calculo passo a passo (exemplo: codigo mais usado):")
242 print(f" a) Anos observados: {cod_tend['n_anos_obs']} anos com registros")
243 print(f" b) Slope bruto: {cod_tend['slope_pct']:.2f}% ao ano")
244 print(f" c) TENDENCIA bruta (mapeada): {50 + cod_tend['slope_pct']:.1f}")
245 print(f" d) R2 da regressao: {cod_tend['R2']:.3f}")
246 print(f" e) TENDENCIA ajustada = 50 + ({50 + cod_tend['slope_pct']:.1f} - 50) *")
247     f" x {cod_tend['R2']:.3f} = {cod_tend['TENDENCIA']:.1f}")
248 print(f"      >> Nota: R2 baixo = pouca confianca = valor proximo de 50 (neutro)")
249
250 # =====
251 # 6. SCORE FINAL
252 # =====
253
254 print("\n" + "=" * 70)
255 print("ETAPA 5: SCORE FINAL")
256 print("=" * 70)
257 print("Formula: SCORE = (ATIVIDADE + TENDENCIA) / 2")
258 print("Razao: Dois componentes independentes medindo dimensoes distintas.")
259 print("")
260
261 stats['SCORE'] = (stats['ATIVIDADE'] + stats['TENDENCIA']) / 2
262
263 # =====
264 # 7. CATEGORIZACAO POR PERCENTIS
265 # =====
266
267 print("\n" + "=" * 70)
268 print("ETAPA 6: CATEGORIZACAO POR PERCENTIS DA DISTRIBUICAO")
269 print("=" * 70)
270 print("Por que percentis: Faixas se ajustam automaticamente a distribuicao.")
271 print("      Sem thresholds fixos ou arbitrarios.")
272 print("")
273
274 def categorizar_por_percentis(score, todos_scores):
275     """
276     Categoriza com base na posicao percentil do score na distribuicao.
277     - >= 90%: Critica (Acao Imediata)
278     - >= 70%: Alta Relevancia
279     - >= 30%: Operacional Media
280     - < 30%: Baixa/Inativa
281     """
282     p = (todos_scores <= score).mean()
283     if p >= 0.90:
284         return 'Critica (Acao Imediata)'
285     elif p >= 0.70:
286         return 'Alta Relevancia'
287     elif p >= 0.30:
288         return 'Operacional Media'
289     else:
290         return 'Baixa/Inativa'
291
292 stats['CATEGORIA'] = stats['SCORE'].apply(
293     lambda s: categorizar_por_percentis(s, stats['SCORE'].values)
294 )
295

```

```

296 print("Distribuicao das categorias:")
297 for cat, count in stats['CATEGORIA'].value_counts().sort_index().items():
298     pct = count / len(stats) * 100
299     print(f" {cat:30s}: {count:4d} codigos ({pct:5.1f}%)")
300
301 # Ordenar por score
302 cols_score = ['COD', 'n_registros', 'anos_ativos', 'vr_registros', 'dias_ultimo_uso',
303               'volume_percentil', 'persistencia_percentil', 'vr_percentil',
304               'recencia_percentil',
305               'ATIVIDADE', 'TENDENCIA', 'SCORE', 'CATEGORIA',
306               'n_anos_obs', 'slope_pct', 'R2', 'confianca']
307 stats = stats[cols_score].sort_values('SCORE', ascending=False).reset_index(drop=True)
308
309 # =====
310 # 8. RESULTADOS -- TOP 20
311 # =====
312
313 print("\n" + "=" * 70)
314 print("TOP 20 CODIGOS MAIS RELEVANTES")
315 print("=" * 70)
316
317 for idx, row in stats.head(20).iterrows():
318     print(f"{idx+1:2d}. {row['COD']:15s} | Score: {row['SCORE']:6.1f} | "
319           f"Ativ: {row['ATIVIDADE']:5.1f} | Tend: {row['TENDENCIA']:5.1f} | "
320           f"Cat: {row['CATEGORIA']}")
321
322 # =====
323 # 9. DIAGNOSTICO DE ROBUSTEZ
324 # =====
325
326 print("\n" + "=" * 70)
327 print("DIAGNOSTICO DE ROBUSTEZ")
328 print("=" * 70)
329
330 # Correlacao entre componentes
331 corr_at = stats['ATIVIDADE'].corr(stats['TENDENCIA'])
332 print(f"\nCorrelacao ATIVIDADE x TENDENCIA: {corr_at:.3f}", end="")
333 if abs(corr_at) > 0.70:
334     print(" [ATENCAO: acima de 0.70]")
335 else:
336     print(" [OK] Componentes sao independentes.")
337
338 # Correlacoes internas de ATIVIDADE
339 print("\nCorrelacoes internas de ATIVIDADE (4 subcomponentes):")
340 subcomp = stats[['volume_percentil', 'persistencia_percentil',
341                  'vr_percentil', 'recencia_percentil']]
342 subcorr = subcomp.corr()
343 nomes_curtos = ['Volume', 'Persistencia', 'VR', 'Recencia']
344 for i in range(4):
345     for j in range(i+1, 4):
346         c = subcorr.iloc[i, j]
347         flag = " [ATENCAO]" if abs(c) > 0.80 else ""
348         print(f" {nomes_curtos[i]} x {nomes_curtos[j]}: {c:.3f}{flag}")
349
350 # Sensibilidade a pesos
351 print("\nSensibilidade a pesos alternativos:")
352 rank_base = stats['SCORE'].rank(ascending=False, method='first').values
353
354 alternativas = {
355     'Ativ 70% / Tend 30%': [0.70, 0.30],
356     'Ativ 30% / Tend 70%': [0.30, 0.70],

```

```

356     'Ativ 60% / Tend 40%': [0.60, 0.40],
357 }
358
359 for nome, pesos in alternativas.items():
360     s = stats['ATIVIDADE'] * pesos[0] + stats['TENDENCIA'] * pesos[1]
361     rank = s.rank(ascending=False, method='first').values
362     valid = ~(np.isnan(rank_base) | np.isnan(rank))
363     if valid.sum() >= 2:
364         corr = np.corrcoef(rank_base[valid], rank[valid])[0, 1]
365         shift = np.abs(rank_base[valid] - rank[valid]).max()
366         print(f" {nome}: corr = {corr:.4f}, shift max = {shift:.0f} posicoes")
367
368 # Distribuicao do score
369 print(f"\nDistribuicao do Score:")
370 print(f" Minimo: {stats['SCORE'].min():.2f}")
371 print(f" Maximo: {stats['SCORE'].max():.2f}")
372 print(f" Media: {stats['SCORE'].mean():.2f}")
373 print(f" Mediana: {stats['SCORE'].median():.2f}")
374 print(f" StdDev: {stats['SCORE'].std():.2f}")
375
376 # Tendencia -- confianca
377 n_r2_baixo = (stats['R2'] < 0.10).sum()
378 pct_r2_baixo = n_r2_baixo / len(stats) * 100
379 print(f"\nConfianca da Tendencia:")
380 print(f" Codigos com R2 < 0.10: {n_r2_baixo} ({pct_r2_baixo:.1f}%)")
381 print(f" -> Estes codigos recebem TENDENCIA proxima de 50 (neutro)")
382
383 # =====
384 # 10. EXPORTACAO CSV + EXCEL
385 # =====
386
387 print("\n" + "=" * 70)
388 print("EXPORTACAO")
389 print("=" * 70)
390
391 stats.to_csv('relevancia_v8.csv', index=False)
392 print("[OK] CSV salvo: relevancia_v8.csv")
393
394 try:
395     stats.to_excel('relevancia_v8.xlsx', index=False, engine='openpyxl')
396     print("[OK] Excel salvo: relevancia_v8.xlsx")
397 except Exception as e:
398     print(f"[AVISO] Falha ao salvar Excel: {e}")
399
400 # =====
401 # 11. GRAFICOS
402 # =====
403
404 print("\n[INFO] Gerando graficos...")
405
406 fig, axes = plt.subplots(2, 2, figsize=(14, 10))
407
408 # 11a. Top 10
409 top10 = stats.head(10)
410 ax = axes[0, 0]
411 bars = ax.barh(range(len(top10)), top10['SCORE'], color='steelblue',
412               edgecolor='white')
413 ax.set_yticks(range(len(top10)))
414 ax.set_yticklabels(top10['COD'])
415 ax.set_xlabel('Score Final (0-100)')
416 ax.set_title('Top 10 -- Codigos Mais Relevantes (V8)')

```

```

416 ax.invert_yaxis()
417 for i, score in enumerate(top10['SCORE']):
418     ax.text(score + 0.5, i, f'{score:.1f}', va='center', fontsize=9)
419
420 # 11b. Scatter: ATIVIDADE vs TENDENCIA
421 ax = axes[0, 1]
422 scatter = ax.scatter(stats['ATIVIDADE'], stats['TENDENCIA'],
423                      c=stats['SCORE'], cmap='viridis',
424                      s=50, alpha=0.7, edgecolors='black', linewidth=0.3,
425                      vmin=0, vmax=100)
426 ax.set_xlabel('ATIVIDADE')
427 ax.set_ylabel('TENDENCIA')
428 ax.set_title('Atividade vs Tendencia (cor = Score)')
429 ax.set_xlim(0, 105)
430 ax.set_ylim(0, 105)
431 plt.colorbar(scatter, ax=ax, label='SCORE')
432
433 # 11c. Histograma do Score
434 ax = axes[1, 0]
435 ax.hist(stats['SCORE'], bins=25, color='steelblue', edgecolor='white', alpha=0.8)
436 ax.axvline(stats['SCORE'].mean(), color='red', linestyle='--', linewidth=2,
437            label=f'Media = {stats["SCORE"].mean():.1f}')
438 ax.axvline(stats['SCORE'].median(), color='green', linestyle='--', linewidth=2,
439            label=f'Mediana = {stats["SCORE"].median():.1f}')
440 ax.set_xlabel('Score Final')
441 ax.set_ylabel('Frequencia')
442 ax.set_title('Distribuicao do Score Final (V8)')
443 ax.legend()
444
445 # 11d. Decomposicao de ATIVIDADE (subcomponentes)
446 ax = axes[1, 1]
447 nomes = ['Volume', 'Persistencia', 'VR', 'Recencia']
448 subcomp_vals = stats[['volume_percentil', 'persistencia_percentil',
449                      'vr_percentil', 'recencia_percentil']].mean()
450 colors = ['#2196F3', '#4CAF50', '#FF9800', '#F44336']
451 bars = ax.bar(nomes, subcomp_vals, color=colors, edgecolor='white')
452 for bar, val in zip(bars, subcomp_vals):
453     ax.text(bar.get_x() + bar.get_width()/2, bar.get_height() + 1,
454            f'{val:.1f}', ha='center', va='bottom', fontsize=11, fontweight='bold')
455 ax.set_ylabel('Percentil Medio')
456 ax.set_title('Decomposicao de ATIVIDADE (medias)')
457 ax.set_ylim(0, 110)
458
459 plt.tight_layout()
460 plt.savefig('v8_graficos.png', dpi=150, bbox_inches='tight')
461 plt.show()
462
463 print("[OK] Graficos salvos: v8_graficos.png")
464
465 # =====
466 # 12. RESUMO FINAL
467 # =====
468
469 print("\n" + "=" * 70)
470 print("RESUMO FINAL V8")
471 print("=" * 70)
472 print(f"Codigos analisados:      {len(stats)}")
473 print(f"Score maximo:                {stats['SCORE'].max():.2f}")
474     ({stats.iloc[0]['COD']})")
475 print(f"Score minimo:                {stats['SCORE'].min():.2f}")
476 print(f"Score medio:                  {stats['SCORE'].mean():.2f}")

```

```
476 print(f"Score mediana:          {stats['SCORE'].median():.2f}")
477 print(f"Corr. ATIVIDADE x TEND:   {corr_at:.3f}")
478 print(f"Componentes:              2 (ATIVIDADE + TENDENCIA)")
479 print(f"Subcomponentes ATIVID:    4 (Volume, Persistencia, VR, Recencia)")
480 print(f"Parametros arbitrarios:    ZERO")
481 print(f"Tetos fixos:              ZERO")
482 print(f"Normalizacao:              Percentis (dados proprios)")
483 print(f"Categorizacao:             Por percentis da distribuicao (adaptativa)")
484 print(f"Correlacao ATIV x TEND: {corr_at:.3f} (independentes, sem multicolinearidade
      entre componentes)")
485 print("=" * 70)
486 print("\nFIM. Verifique os arquivos gerados:")
487 print("  - relevancia_v8.csv    (base completa, universal)")
488 print("  - relevancia_v8.xlsx    (Excel, pronto para gestores)")
489 print("  - v8_graficos.png       (visualizacoes)")
490 print("=" * 70)
```